МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

ЗВІТ

з дисципліни «Аналіз кіберінцидентів»

Практичне заняття № 2 — Дерево рішень і ліс дерев рішень

Виконав: Вовкотруб Олександр Віталійович
Група: ФБ-61мн

Перевірив: Наконечна Юлія Володимирівна

Київ — 2026

Зміст

1 Мета роботи **2**

2 Постановка задачі **2**

3 Хід виконання **2**

3.1 Підготовка даних 2

3.2 Перевірка на витік даних 3

3.3 Дерево рішень і вплив глибини 3

4 Результати **5**

5 Аналіз **6**

5.1 Нелінійність задачі визначає виграш від дерев 6

5.2 Коли ансамбль справді допомагає 6

5.3 Переваги й недоліки алгоритмів 7

6 Висновки **8**

7 Джерела **8**

1 Мета роботи

Застосувати алгоритми дерева рішень та лісу дерев рішень до трьох датасетів, проаналізувати переваги й недоліки обох алгоритмів та встановити, **від яких саме особливостей даних** залежить якість класифікації.

2 Постановка задачі

Роботу побудовано як **порівняння трьох датасетів однаковим конвеєром аналізу**: однакова підготовка, однакові моделі, однакові метрики. Тоді різницю в результатах можна приписати саме властивостям даних, а не відмінностям методики.

	UGRansome	NSL-KDD	Intrusion 2025
Записів	149 043	25 192	9 537
Ознак	13	39	9
Класів	3 (`S`/`A`/`SS`)	2 (`normal`/`anomaly`)	2 (`0`/`1`)
Базова лінія	0.4454	0.5339	0.5529
Домен	трафік вимагачів	мережеві вторгнення	сесії доступу
Пропуски	немає	немає	1 966 (`encryption_used`)

Датасети обрано навмисне різними за структурою — саме це дозволяє зробити висновки про вплив даних, а не лише виміряти точність.

3 Хід виконання

3.1 Підготовка даних

Єдиний конвеєр: видалення ідентифікаторів і константних колонок, кодування категоріальних ознак цілими числами. Масштабування деревам не потрібне.

- **NSL-KDD**: видалено дві константні колонки `num_outbound_cmds`, `is_host_login`.
- **Intrusion 2025**: видалено `session_id` — унікальний ідентифікатор сесії. Важливо: колонки `session_duration` та `ip_reputation_score` теж майже унікальні, але це **неперервні числові ознаки**, для яких це нормально; їх видаляти не можна. Пропуски (1 966 у `encryption_used`, 20.6 %) закодовано окремою категорією `-1` — для дерева «невідомо» є повноцінним значенням, що коректніше за підстановку моди.

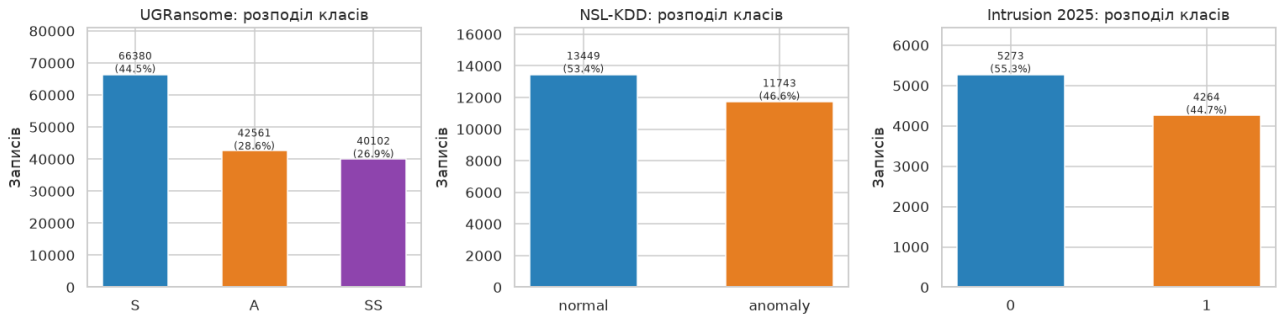


Рисунок 1: Розподіл класів

3.2 Перевірка на витік даних

Повних дублікатів рядків немає в жодному датасеті. Для NSL-KDD це очікувано: усунення дублікатів KDD'99 було головною метою його створення.

Жодна окрема колонка не визначає мітку повністю. Найсильніші:

Датасет	Найсильніша колонка	Середня чистота	Частка рядків у «чистих» категоріях
UGRansome	`SeddAddress`	0.683	10.5 %
NSL-KDD	`diff_srv_rate`	0.870	**29.1 %**
Intrusion 2025	`failed_logins`	0.831	16.6 %

У NSL-KDD майже третина рядків потрапляє в категорії `diff_srv_rate` з однозначною міткою, причому три найсильніші колонки дають 29.1 %, 27.6 % і 27.0 % — тобто таких «майже готових» ознак там одразу кілька. Це не витік, але означає, що значну частину задачі розв'язує один запит до однієї ознаки — і це пояснює, чому на NSL-KDD добре працює навіть неглибоке дерево.

3.3 Дерево рішень і вплив глибини

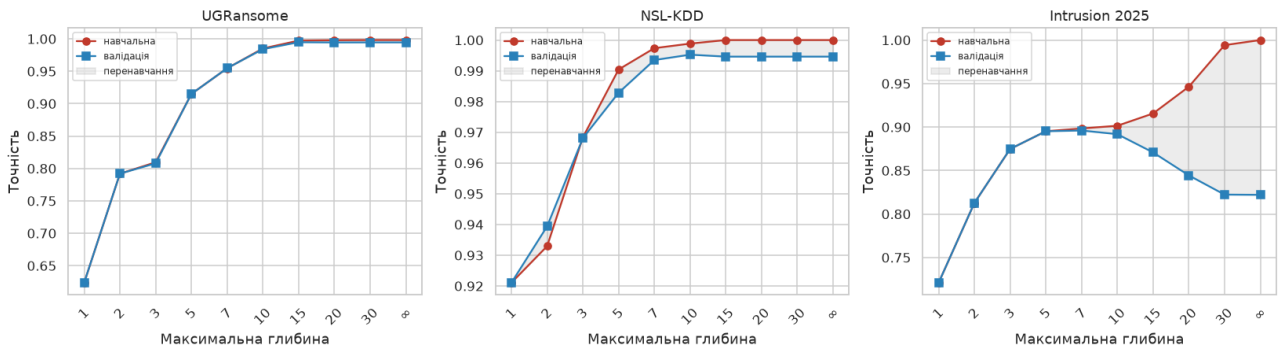


Рисунок 2: Криві валідації за глибиною

Датасет	`max_depth=5`	Без обмежень	Висновок
UGRansome	55 вузлів, 0.9156	1 465 вузлів, глибина 26, **0.9935**	глибина допомагає
NSL-KDD	47 вузлів, 0.9889	193 вузли, глибина 13, **0.9943**	глибина майже не потрібна
Intrusion 2025	**13 вузлів, 0.8834**	1 739 вузлів, глибина 36, 0.8159	глибина **шкодить**

Найважливіший результат таблиці — останній рядок. На Intrusion 2025 повне дерево **гірше за неглибоке на 6.8 пункта**: 1 739 вузлів дають 0.8159, а 13 вузлів — 0.8834. Це класичне перенавчання у чистому вигляді, і воно проявилось лише на тому датасеті, де в даних є справжній шум.

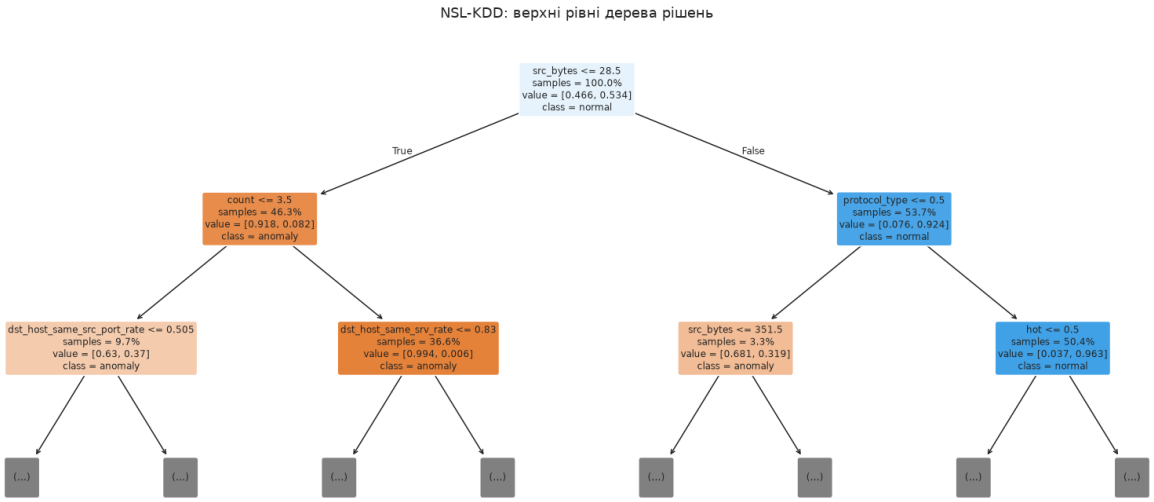


Рисунок 3: NSL-KDD: верхні рівні дерева

4 Результати

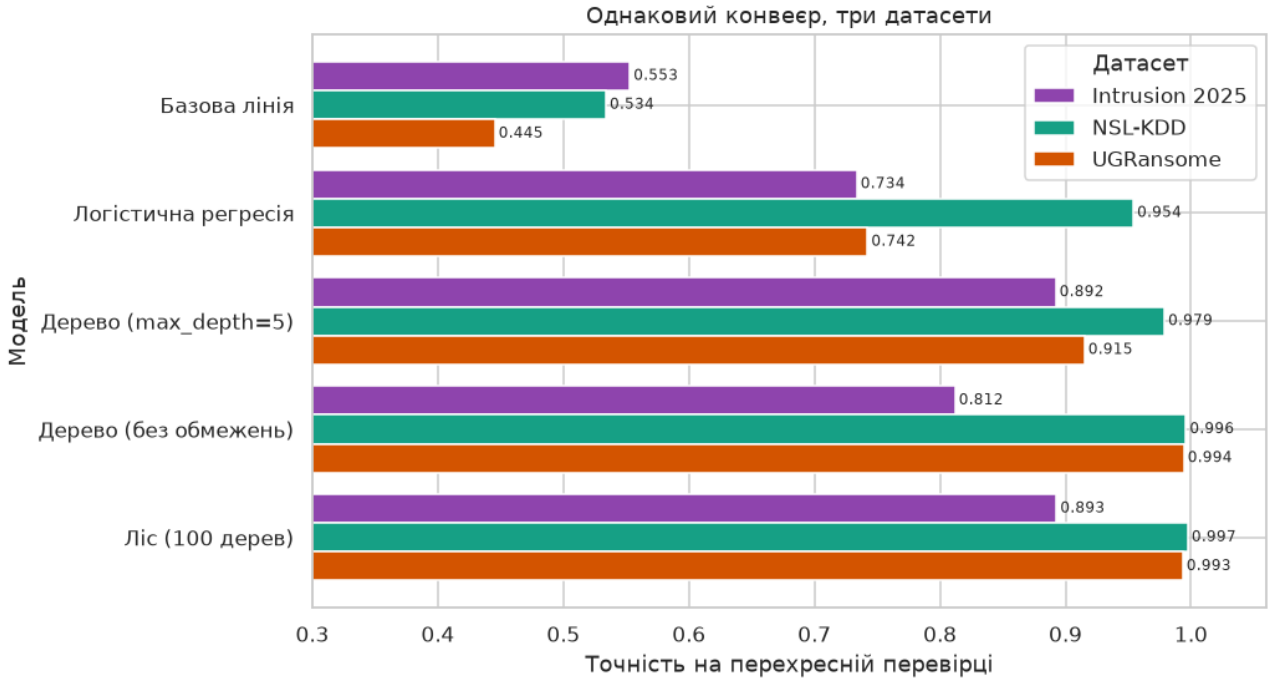


Рисунок 4: Порівняння методів

Модель	UGRansome	NSL-KDD	Intrusion 2025
Базова лінія	0.4454	0.5339	0.5529
Логістична регресія	0.7423	0.9541	0.7338
Дерево (`max_depth=5`)	0.9151	0.9788	**0.8922**
Дерево (без обмежень)	**0.9943**	0.9959	0.8120
Ліс (100 дерев)	0.9934	**0.9975**	**0.8928**

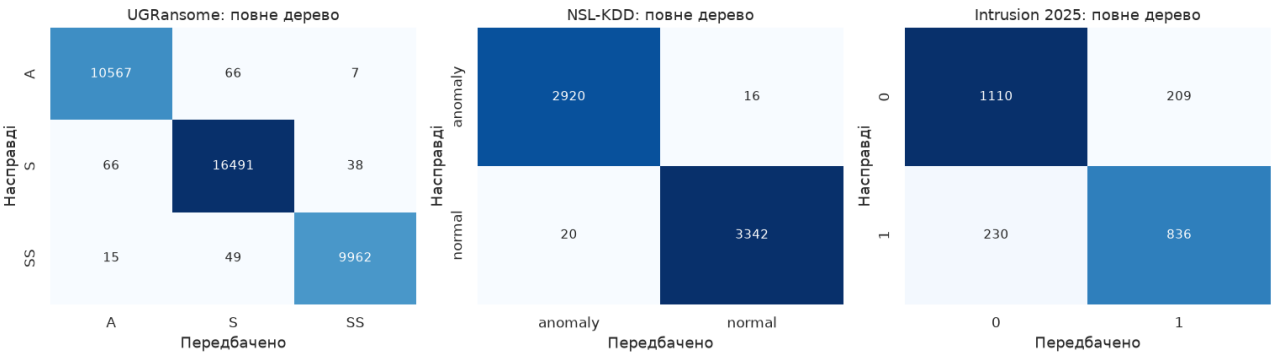


Рисунок 5: Матриці невідповідностей

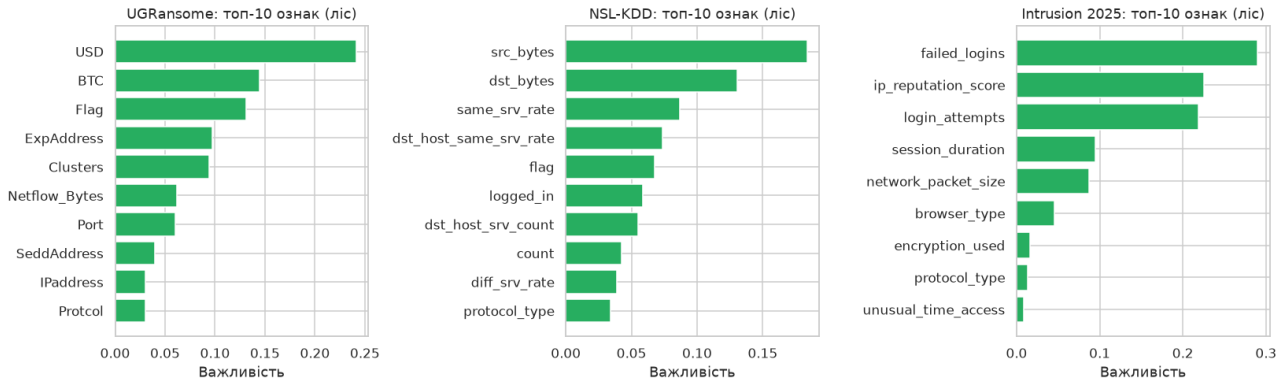


Рисунок 6: Важливість ознак

5 Аналіз

5.1 Нелінійність задачі визначає виграш від дерев

Датасет	LogReg	Дерево	Розрив
UGRansome	0.7423	0.9943	**+0.2521**
Intrusion 2025	0.7338	0.8120	+0.0782
NSL-KDD	0.9541	0.9959	+0.0418

На UGRansome лінійна модель відстає на 25 пунктів: залежність має вигляд комбінацій умов («протокол TCP **і** порт 5062 **і** обсяг трафіку в діапазоні»), а не зваженої суми. На NSL-KDD розрив ушестеро менший — дані значною мірою лінійно роздільні. Отже, **виграш від переходу до дерев визначається структурою даних, а не якістю алгоритму**.

5.2 Коли ансамбль справді допомагає

Різниця «ліс − повне дерево» кардинально різна на трьох датасетах:

Датасет	Ліс − дерево
UGRansome	−0.0009
NSL-KDD	+0.0015
Intrusion 2025	**+0.0808**

На двох датасетах ансамбль не дає нічого, на третьому — рятує вісім пунктів. Це не випадковість, а прямий наслідок наявності шуму: ліс бореться з **дисперсією**, усереднюючи багато дерев. Коли залежність детермінована, повне дерево вивчає правила точно й гасити немає чого; коли в даних шум, окреме глибоке дерево запам’ятовує його, а усереднення це виправляє.

Гіпотезу перевірено керованим експериментом на всіх трьох датасетах: до міток додавався шум, вимірювалась перевага лісу.

Частка доданого шуму	UGRansome	NSL-KDD	Intrusion 2025
0 %	−0.0001	+0.0015	**+0.0744**
5 %	+0.0373	+0.0289	+0.0890
10 %	+0.0624	+0.0549	+0.1047
20 %	+0.0972	+0.0821	+0.1166
30 %	+0.1095	+0.0996	+0.1258

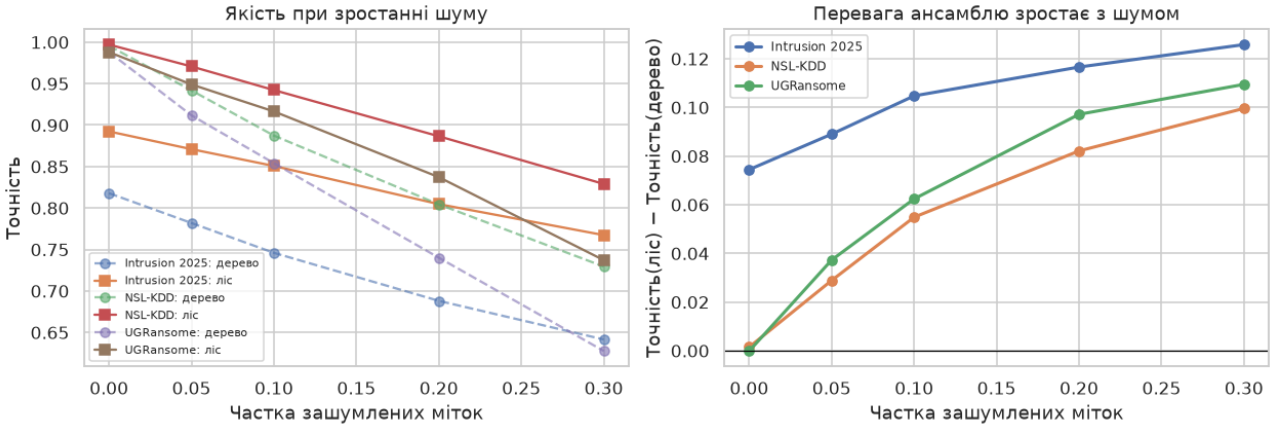


Рисунок 7: Перевага ансамблю зростає з шумом

Два спостереження. По-перше, залежність монотонна на всіх трьох наборах — від нуля до приблизно 10–13 пунктів. По-друге, і це головне: **стовпець «0 % доданого шуму» вимірює власний шум датасету**. UGRansome і NSL-KDD стартують з нуля, бо вони майже детерміновані; Intrusion 2025 стартує з +0.0744, бо шум у ньому вже є. Тобто експеримент зі штучним шумом і природна поведінка трьох датасетів дають узгоджену картину.

5.3 Переваги й недоліки алгоритмів

Дерево рішень. Переваги: не потребує масштабування; природно працює з категоріальними ознаками та пропусками; при обмеженій глибині повністю інтерпретується (13 вузлів на Intrusion 2025, 47 на NSL-KDD); навчається швидко. Недоліки: без обмеження глибини перенавчається — на Intrusion 2025 це коштувало 6.8 пункта; нестабільне; на складноструктурованих даних розростається до півтори тисячі вузлів і втрачає інтерпретованість.

Ліс дерев. Переваги: стійкий до перенавчання; на зашумлених даних дає до +8 пунктів без будь-якого підбору параметрів; надійніші оцінки важливості ознак. Недоліки: втрата інтерпретованості; навчання в десятки разів повільніше; **на чистих детермінованих даних не дає переваги взагалі**.

6 Висновки

1. Обидва алгоритми застосовано до трьох датасетів однаковим конвеєром. Найкращі результати: UGRansome — дерево без обмежень 0.9943; NSL-KDD — ліс 0.9975; Intrusion 2025 — ліс 0.8928.
2. Нелінійність визначає виграш від дерев: розрив «логістична регресія → дерево» становить +0.2521 на UGRansome, +0.0782 на Intrusion 2025 і лише +0.0418 на NSL-KDD.
3. Глибина дерева має оптимум, і він залежить від шуму. На чистих даних глибше дерево краще; на зашумлених Intrusion 2025 дерево з 13 вузлів перевершує дерево з 1 739 вузлів на 6.8 пункта.
4. Ансамбль корисний рівно настільки, наскільки в даних є шум. Перевага лісу становить −0.001 і +0.002 на двох майже детермінованих датасетах і +0.081 на зашумленому; керованим експериментом показано монотонне зростання цієї переваги з рівнем доданого шуму на всіх трьох наборах.
5. Якість класифікації визначається переважно даними, а не вибором алгоритму. Різниця між найкращим і найгіршим датасетом (0.9975 проти 0.8928) значно перевищує різницю між алгоритмами в межах одного датасету.
6. Методологічний висновок: датасет для порівняння алгоритмів слід обирати за розкидом результатів між методами; набір із практичного заняття № 1 має розкид 0.005 і для такого порівняння непридатний.

7 Джерела

1. UGRansome dataset. URL: https://www.kaggle.com/datasets/nkongolo/ugransome-dataset
2. Network Intrusion Detection (NSL-KDD). URL: https://www.kaggle.com/datasets/sampadab17/network intrusion-detection
3. Cybersecurity Intrusion Detection Dataset. URL: https://www.kaggle.com/datasets/dnkumars/cybersecu intrusion-detection-dataset
4. Tavallaee M. et al. A Detailed Analysis of the KDD CUP 99 Data Set // IEEE CISDA. 2009.
5. Breiman L. Random Forests // Machine Learning. 2001. Vol. 45. P. 5–32.
6. Scikit-learn: Decision Trees. URL: https://scikit-learn.org/stable/modules/tree.html