МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

ЗВІТ

з дисципліни «Аналіз кіберінцидентів»

Практичне заняття № 3 — Метод опорних векторів

Виконав: Вовкотруб Олександр Віталійович
Група: ФБ-61мн

Перевірив: Наконечна Юлія Володимирівна

Київ — 2026

Зміст

1 Мета роботи **2**

2 Постановка задачі **2**

3 Хід виконання **2**

3.1 Фактор 1: масштабування ознак 2

3.2 Фактор 2: вибір ядра 3

3.3 Фактор 3: гіперпараметри C і gamma 4

3.4 Фактор 4: розмір вибірки й обчислювальна складність 5

3.5 Опорні вектори підсумкової моделі 6

4 Результати **7**

5 Аналіз **8**

6 Висновки **8**

7 Джерела **9**

1 Мета роботи

Реалізувати алгоритм методу опорних векторів (SVM), оцінити його точність на задачі класифікації зловмисної мережевої активності та дослідити фактори, від яких ця точність залежить.

2 Постановка задачі

Використано датасет **UGRansome** — той самий, що й у практичному занятті № 2. Вибір навмисний: на цих даних уже виміряно логістичну регресію, дерево рішень і випадковий ліс, тож результат SVM можна порівняти безпосередньо.

Метод опорних векторів шукає гіперплощину, що максимізує відступ між класами. Точки на межі відступу — **опорні вектори** — визначають рішення повністю; решта прикладів на модель не впливає. Для нелінійно роздільних даних застосовують ядровий трюк: неявне відображення у простір вищої розмірності.

Обмеження, що визначило методику. Складність навчання SVM лежить між $O(n^2)$ і $O(n^3)$. Заміри показали, що навчання на 40 000 прикладів триває 6.4 с, а перехресна перевірка на повних 149 043 рядках потребувала б десятків хвилин на кожну конфігурацію. Тому основні експерименти виконано на стратифікованій підвибірці 30 000 записів, а сітку гіперпараметрів — на 10 000. Через це абсолютні числа трохи відрізняються від практичного заняття № 2 (там повні дані та 5 блоків), але всі моделі в цьому звіті оцінено **однаково**, тож порівняння між ними коректне.

3 Хід виконання

3.1 Фактор 1: масштабування ознак

Найважливіша практична відмінність SVM від дерев. Дерево працює з порогами по кожній ознаці окремо, тому масштаб йому байдужий. SVM вимірює **відстані** між точками, і ознака з великим діапазоном заглушує решту.

У UGRansome розмахи ознак відрізняються у **63 189 разів**:

Ознака	Мінімум	Максимум	Розмах
`USD`	1	126 379	126 378
`Netflow_Bytes`	1	12 352	12 351
`BTC`	1	1 980	1 979
`Flag`	0	8	8

Підготовка	Точність	Час, с
Без масштабування	**0.6354**	65.7
StandardScaler	**0.9552**	18.8
MinMaxScaler	0.9435	23.0

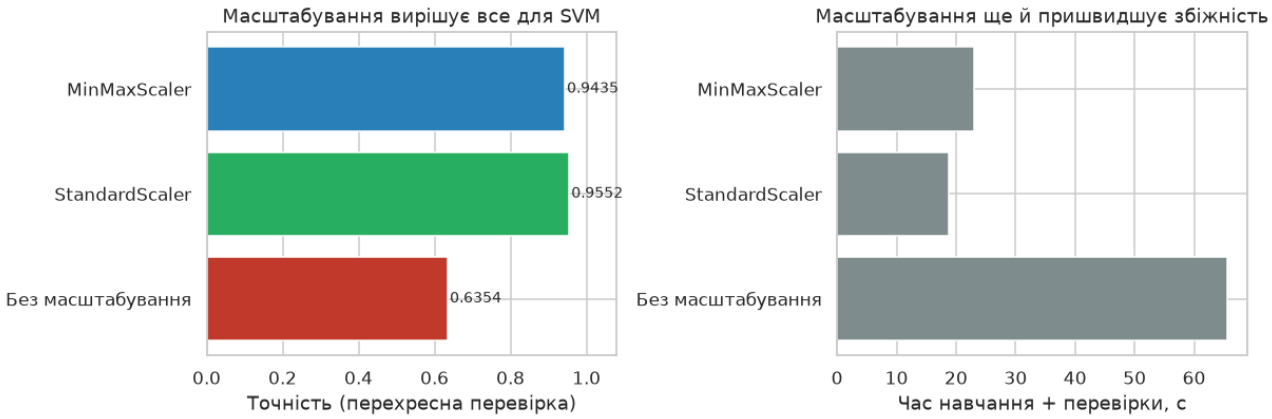


Рисунок 1: Вплив масштабування

Масштабування дає **+32 процентні пункти** точності й водночас пришвидшує навчання у 3.5 раза. Без нього відстань між точками визначається майже виключно колонкою `USD`, і решта дванадцяти ознак не впливає на рішення. Це найбільший одиничний ефект з усіх досліджених факторів.

3.2 Фактор 2: вибір ядра

Ядро	Точність	Час, с
Лінійне (`LinearSVC`)	0.7559	**0.52**
Лінійне (`SVC`)	0.7606	57.8
Поліноміальне (degree = 3)	0.9478	18.6
RBF (гаусове)	**0.9552**	21.5

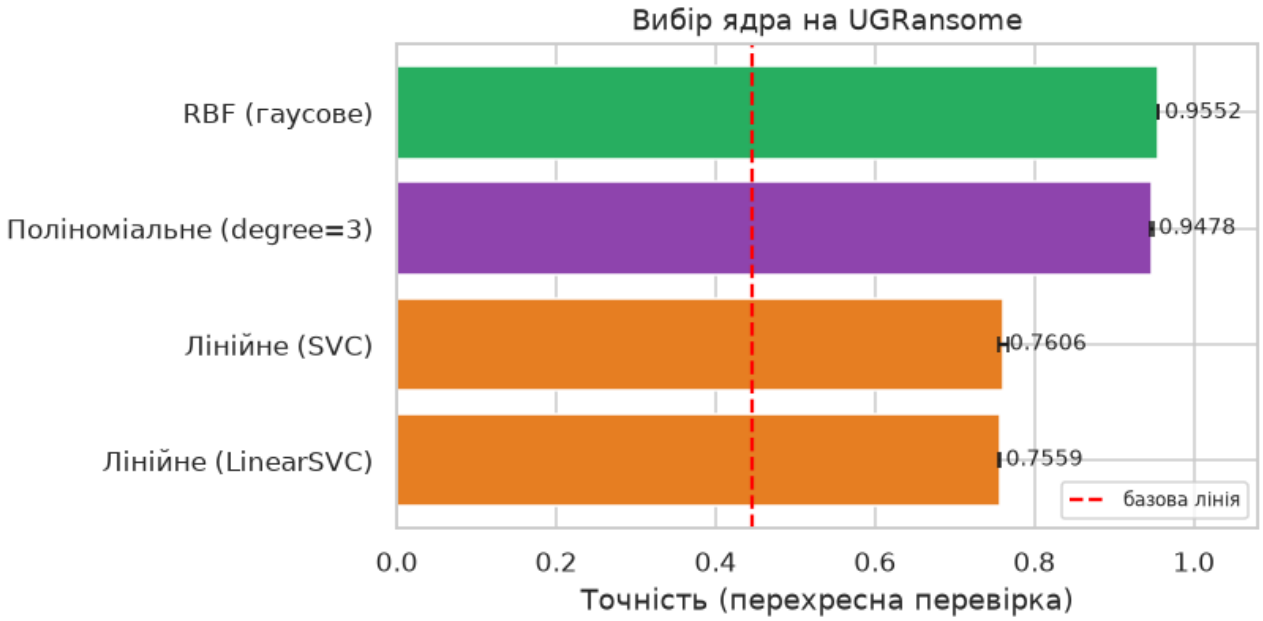


Рисунок 2: Порівняння ядер

Лінійне ядро дає 0.76 — практично те саме, що й логістична регресія (0.748), і це логічно: обидві моделі будують гіперплощину у вихідному просторі. Перехід до RBF-ядра додає **20 пунктів**, що вкотре підтверджує нелінійність задачі, встановлену в практичному занятті № 2.

Окремо варто відзначити різницю в реалізаціях: `LinearSVC` і `SVC(kernel="linear")` дають майже однакову точність, але перша працює **у 73 разів швидше** (0.52 с проти 57.8 с), бо використовує спеціалізований розв'язувач замість загального ядрового. Для лінійного випадку загальний алгоритм застосовувати не варто.

3.3 Фактор 3: гіперпараметри C і gamma

`C` — штраф за помилки: малий дає широкий відступ і недонавчання, великий змушує класифікувати навчальні дані точно. `gamma` — радіус впливу прикладу в RBF-ядрі: малий робить межу майже лінійною, великий — рваною та перенавченою.

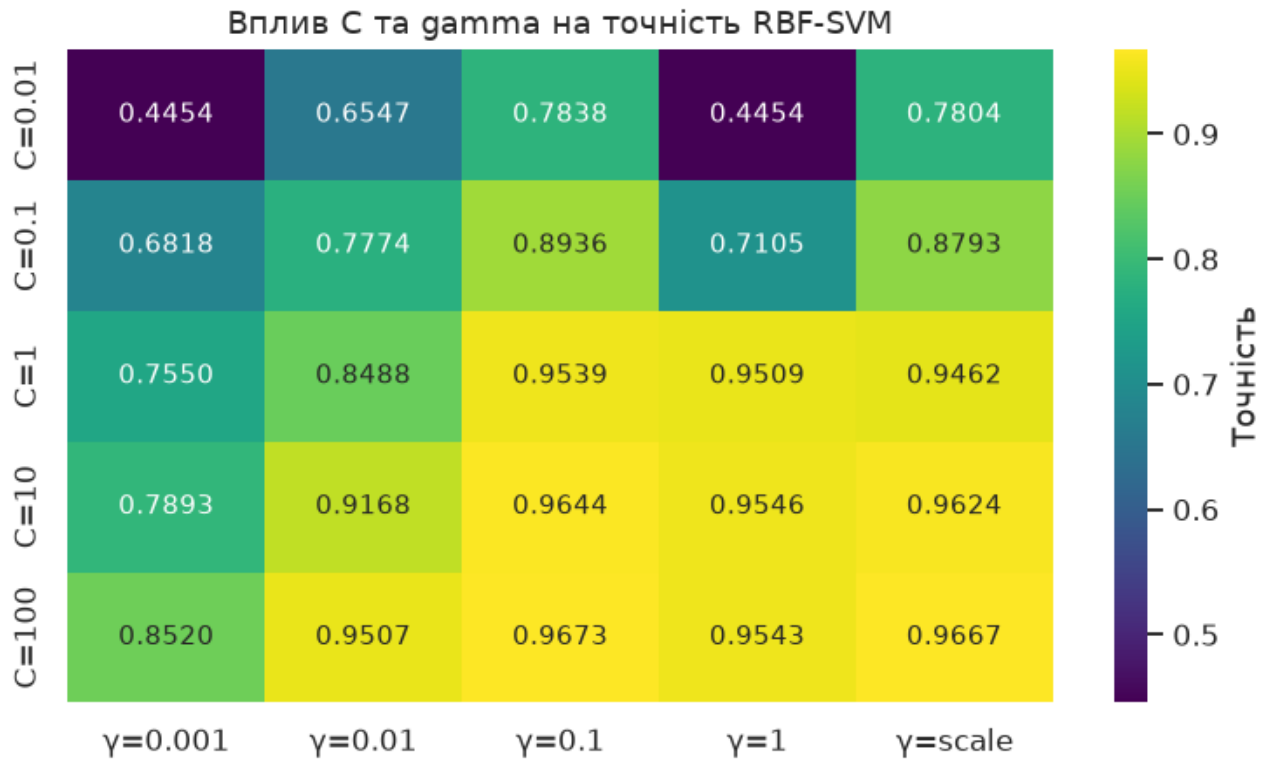


Рисунок 3: Теплова карта C × gamma

Найкраща конфігурація: **C = 100, gamma = 0.1** → 0.9673. Карта показує чітку діагональну структуру: великий `C` компенсує малий `gamma` і навпаки, тому підбирати ці параметри окремо один від одного не можна.

3.4 Фактор 4: розмір вибірки й обчислювальна складність

Розмір	Точність	Час навчання, с	Опорних векторів	Частка опорних
1 000	0.8960	0.02	413	55.1%
5 000	0.9288	0.24	1 402	37.4%
20 000	0.9478	2.43	3 495	23.3%
40 000	**0.9564**	**8.62**	5 699	19.0%

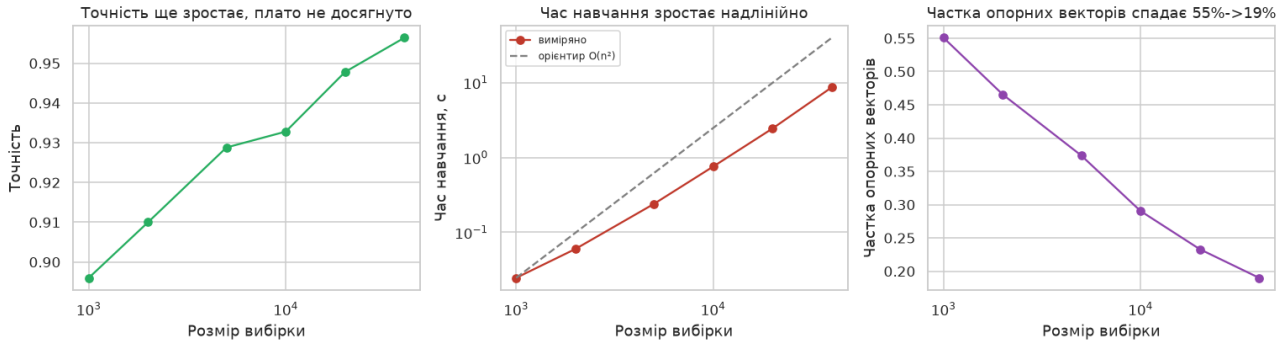


Рисунок 4: Розмір вибірки, точність і час

Дані зросли у 40 разів, час навчання — приблизно у 349 разів; емпіричний показник степеня становить **≈ 1.59**, тобто зростання надлінійне, хоча й не строго квадратичне (бібліотека libsvm застосовує кешування ядра).

Практичний наслідок: **точність на 40 000 прикладів ще не вийшла на плато** (0.9564 і продовжує зростати), але подальше збільшення вибірки коштує надто дорого. Дерево рішень натомість опрацьовує всі 149 043 записи за секунди. Тобто на цьому датасеті SVM обмежений не якістю алгоритму, а неможливістю використати всі наявні дані.

Частка опорних векторів падає з 55 % до 19 % зі зростанням вибірки — модель стає відносно компактнішою, хоча в абсолютних числах опорних векторів більшає.

3.5 Опорні вектори підсумкової моделі

Модель `SVC(kernel="rbf", C=100, gamma=0.1)` на 22 500 навчальних прикладах використовує **2 212 опорних векторів (9.8 %)**, розподілених за класами як `A`: 852, `S`: 828, `SS`: 532. Тобто рішення визначає одна десята вибірки.

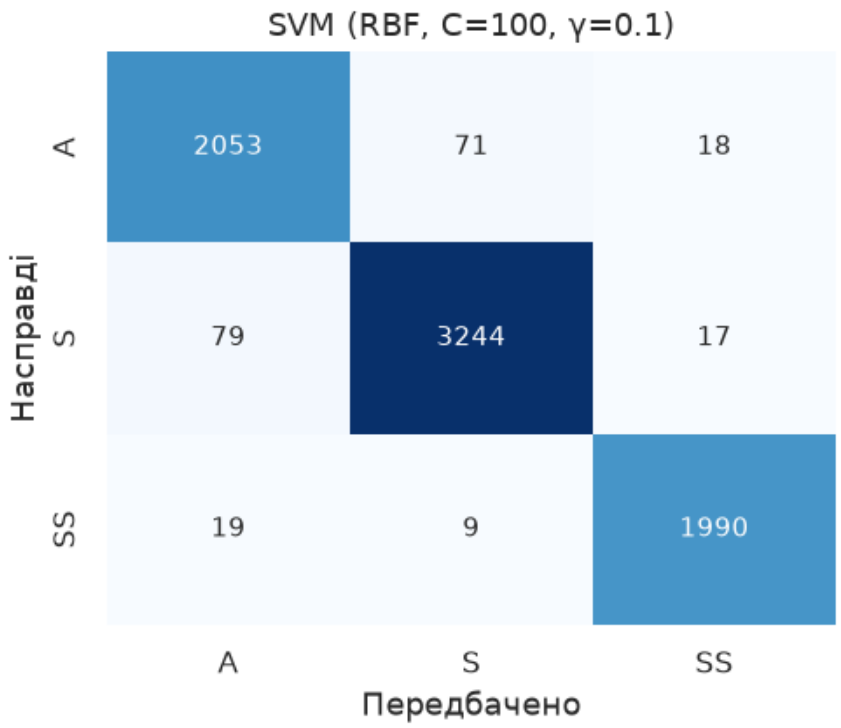


Рисунок 5: Матриця невідповідностей

Точність на тестовій вибірці — 0.9716, F1-macro — 0.9715, найгірше розпізнається клас A (F1 = 0.9564), найкраще SS (F1 = 0.9844).

4 Результати

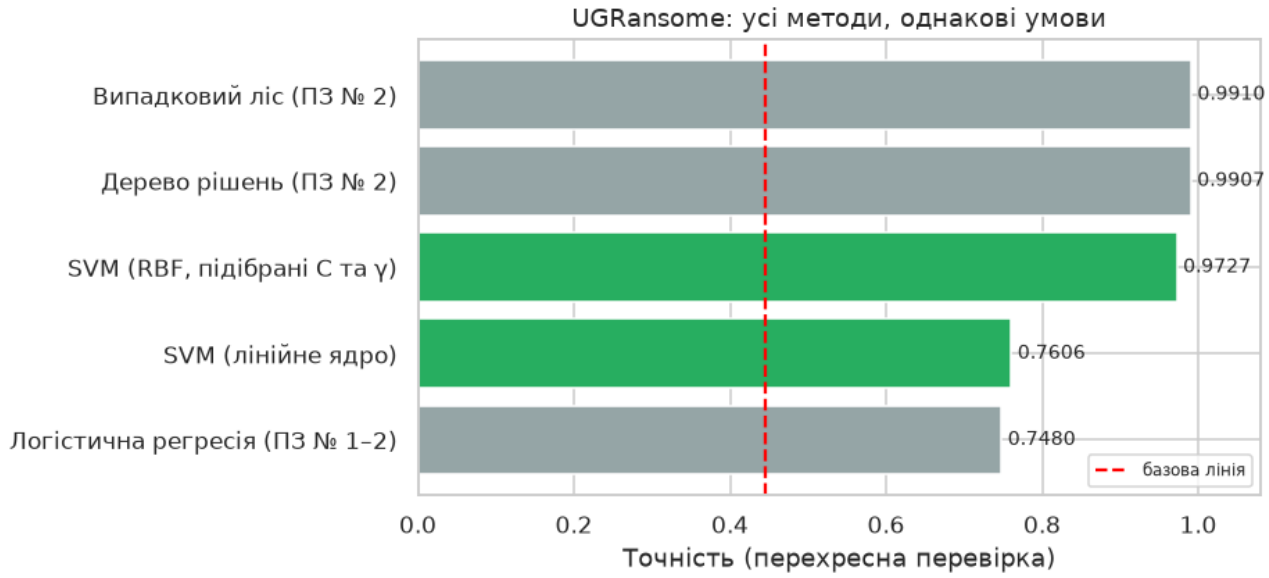


Рисунок 6: Порівняння всіх методів

Модель	Точність (CV)	F1-macro
Випадковий ліс (ПЗ № 2)	**0.9910**	0.9914
Дерево рішень (ПЗ № 2)	0.9907	0.9905
SVM (RBF, C = 100, γ = 0.1)	**0.9727**	0.9715
SVM (лінійне ядро)	0.7606	0.7373
Логістична регресія (ПЗ № 1–2)	0.7480	0.7263

Усі моделі оцінено на одній і тій самій підвибірці 30 000 записів з триблоковою перехресною перевіркою.

5 Аналіз

SVM працює добре, але програє деревам на цих даних. RBF-SVM дає 0.9727 проти 0.9907 у дерева — відставання на 1.8 пункта. При цьому SVM коштує значно дорожче: навчання на 30 000 прикладів триває секунди, тоді як дерево обробляє повні 149 043 записи майже миттєво.

Причина в структурі даних. UGRansome складається переважно з категоріальних ознак з невеликою кількістю рівнів (`Flag` — 9 значень, `Threats` — 9, `Protcol` — 3). Дерево розділяє такі ознаки природно, одним розбиттям на категорію. SVM же змушений будувати гладку межу у неперервному просторі, куди ці категорії довелося закодувати цілими числами — а це нав'язує їм неіснуючий порядок. Метод опорних векторів сильніший там, де ознаки справді неперервні й межа між класами гладка.

Ієрархія факторів. За величиною впливу на точність:

1. масштабування ознак — **+32 пункти** (0.6354 → 0.9552);
2. вибір ядра — **+20 пунктів** (лінійне 0.7559 → RBF 0.9552);
3. підбір `C` і `gamma` — **+1.2 пункта** (0.9552 → 0.9673);
4. збільшення вибірки вдвічі — **+0.9 пункта** (0.9478 при 20 тис. → 0.9564 при 40 тис.).

Найбільший виграш дає найпростіша дія. Підбір гіперпараметрів, на який зазвичай витрачають найбільше зусиль, тут дав у 26 разів менший ефект, ніж один рядок з `StandardScaler`.

6 Висновки

1. Метод опорних векторів реалізовано на датасеті UGRansome; найкраща конфігурація — RBF-ядро з `C = 100` та `gamma = 0.1` — дала точність 0.9727 і F1-macro 0.9715 за базової лінії 0.4454.
2. Масштабування ознак — вирішальний фактор для SVM: без нього точність падає до 0.6354, бо ознака `USD` з розмахом 126 378 заглушує решту. Це відмінність від дерев рішень, яким масштаб байдужий.

3. Нелінійність задачі підтверджено втретє: лінійне ядро дає 0.7606, майже збігаючись з логістичною регресією (0.7480), тоді як RBF додає 20 пунктів.
4. SVM погано масштабується: емпірична складність ≈ O(n^1.59), і на 40 000 прикладів точність ще зростає, але подальше збільшення вибірки обчислювально недоцільне. Це не дозволяє використати всі 149 043 записи, доступні деревам.
5. На цих даних SVM програє деревам (0.9727 проти 0.9907) через переважно категоріальну природу ознак: кодування категорій цілими числами нав'язує їм неіснуючий порядок, з яким гладка ядрова межа працює гірше за дискретні розбиття дерева.
6. Для лінійного випадку слід застосовувати `LinearSVC`, а не `SVC(kernel="linear")` — та сама точність за час, менший у 73 разів.

7 Джерела

1. UGRansome dataset. URL: https://www.kaggle.com/datasets/nkongolo/ugransome-dataset
2. Cortes C., Vapnik V. Support-Vector Networks // Machine Learning. 1995. Vol. 20. P. 273–297.
3. Scikit-learn: Support Vector Machines. URL: https://scikit-learn.org/stable/modules/svm.html
4. Chang C.-C., Lin C.-J. LIBSVM: A Library for Support Vector Machines // ACM TIST. 2011.