МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

ЗВІТ

з дисципліни «Аналіз кіберінцидентів»

Практичне заняття № 4 — Наївний байєсівський класифікатор

Виконав: Вовкотруб Олександр Віталійович
Група: ФБ-61мн

Перевірив: Наконечна Юлія Володимирівна

Київ — 2026

Зміст

1 Мета роботи **2**

2 Постановка задачі **2**

3 Хід виконання **2**

3.1 Векторизація 2

3.2 Дослідження проблеми нульової ймовірності 3

3.2.1 Масштаб проблеми 3

3.2.2 Наслідки на тестовій вибірці 3

3.2.3 Конкретний приклад 3

3.2.4 Згладжування Лапласа 4

3.3 Різновиди наївного Баєса 5

3.4 Найінформативніші слова 6

4 Результати **7**

5 Аналіз **8**

6 Висновки **9**

7 Джерела **9**

1 Мета роботи

Створити спам-фільтр на основі наївного байєсівського класифікатора та дослідити проблему нульової ймовірності, яка є головною вразливістю цього алгоритму.

2 Постановка задачі

Використано датасет SMS Spam Collection (UCI): 5 572 SMS-повідомлення англійською, з них 747 спаму (13.4 %) і 4 825 звичайних (`ham`).

За теоремою Баєса ймовірність належності повідомлення до класу c за умови спостереження слів $w_1 \dots w_n$ пропорційна $P(c) \cdot P(w_1 \dots w_n \mid c)$. Класифікатор називається наївним, бо припускає умовну незалежність слів:

$$P(w_1 \dots w_n \mid c) \approx \prod_{i=1}^{n} P(w_i \mid c)$$

Для природної мови це припущення очевидно хибне, оскільки слова корелюють, але на практиці метод працює непогано.

Позитивною подією вважаємо спам. Для користувача хибнопозитивне спрацювання (заблоковане нормальне повідомлення) гірше за пропущений спам, тому окремо стежимо за precision.

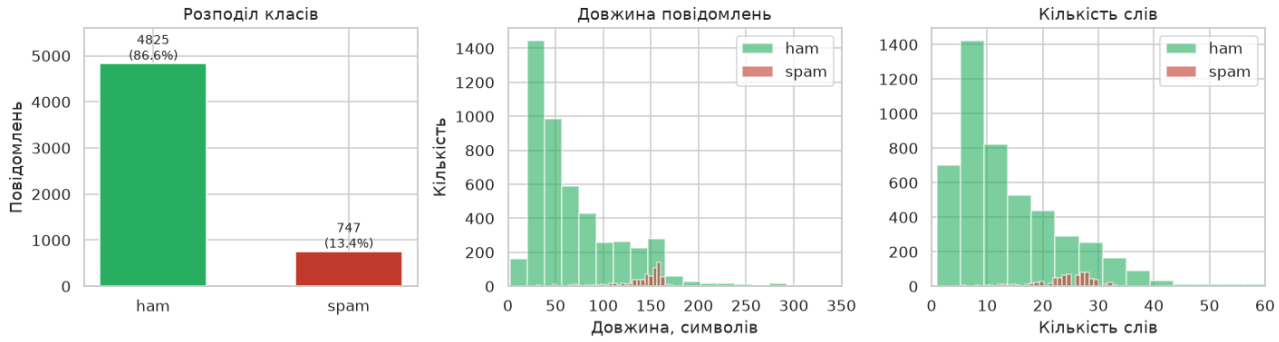


Рисунок 1: Огляд датасету

3 Хід виконання

3.1 Векторизація

`CountVectorizer` будує словник за навчальною вибіркою і перетворює кожне повідомлення на вектор частот слів. Розмір словника 7 534 слова, матриця ознак заповнена на 0.18 %.

Саме те, що словник будується лише за навчальними даними, і породжує проблему нульової ймовірності: у тестових повідомленнях неминуче зустрічаються слова, яких модель не бачила.

3.2 Дослідження проблеми нульової ймовірності

Оцінка ймовірності слова є частотною:

$$P(w_i \mid c) = \frac{\text{count}(w_i, c)}{\sum_w \text{count}(w, c)}$$

Якщо слово жодного разу не зустрілось у документах класу c, то $P(w_i \mid c) = 0$, і весь добуток обертається на нуль незалежно від решти слів. Одне незнайоме слово анулює всі інші свідчення.

3.2.1 Масштаб проблеми

Показник	Значення
Слів у словнику	7 534
Зустрічаються тільки в `ham`	5 052 (67.1 %)
Зустрічаються тільки в `spam`	1 594 (21.2 %)
Разом «однокласових» слів	6 646 (88.2 %)

Для 88 % словника одна з умовних імовірностей дорівнює нулю ще до того, як класифікатор побачив тестові дані.

3.2.2 Наслідки на тестовій вибірці

Реалізовано власний наївний Баєс з керованим згладжуванням, щоб побачити механізм, а не лише результат бібліотеки. Обчислення виконуються в логарифмах: добуток сотень імовірностей інакше спричиняє машинне зникнення порядку (underflow).

Без згладжування ($\alpha = 0$) на 1 393 тестових повідомленнях:

Ситуація	Повідомлень
$\log P(\text{spam} \mid d) = -\infty$	1 153
$\log P(\text{ham} \mid d) = -\infty$	238
Обидві $-\infty$, рішення неможливе	106 (7.6 %)

Для 7.6 % повідомлень класифікатор без згладжування не може ухвалити рішення взагалі: обидва добутки нульові, і вибір вироджується у значення за замовчуванням.

3.2.3 Конкретний приклад

```
Hi babe its Jordan, how r u? Im home from abroad and lonely, text me
back if u    wanna chat xxSP visionsms.com Text stop to stopCost 150p
08712400603
```

Це справжній спам, але:

- слово `lonely` не зустрічалось у навчальному спамі, тому $P(\text{lonely} \mid \text{spam}) = 0$;
- слова `150p`, `jordan`, `visionsms` не зустрічались у навчальному `ham`, тому $P(\cdot \mid \text{ham}) = 0$.

Обидва добутки перетворюються на нуль, і повідомлення стає нерозпізнаваним, попри те, що `visionsms` і `150p` є очевидними ознаками спаму.

3.2.4 Згладжування Лапласа

Проблема усувається додаванням псевдовідліку α:

$$P(w_i \mid c) = \frac{\text{count}(w_i, c) + \alpha}{\sum_w \text{count}(w, c) + \alpha \cdot |V|}$$

За $\alpha = 1$ це класичне згладжування Лапласа, за $0 < \alpha < 1$ згладжування Лідстоуна.

α	Невизначених	Точність	Precision	Recall	F1
0	106	0.9562	0.9437	0.7166	0.8146
10^{-10}	0	0.9799	0.9543	0.8930	0.9227
0.01	0	0.9842	0.9609	0.9198	0.9399
0.1	0	0.9864	0.9667	0.9305	0.9482
1.0	0	0.9856	0.9771	0.9144	0.9448
5.0	0	0.9698	1.0000	0.7754	0.8735
50.0	0	0.8945	1.0000	0.2139	0.3524

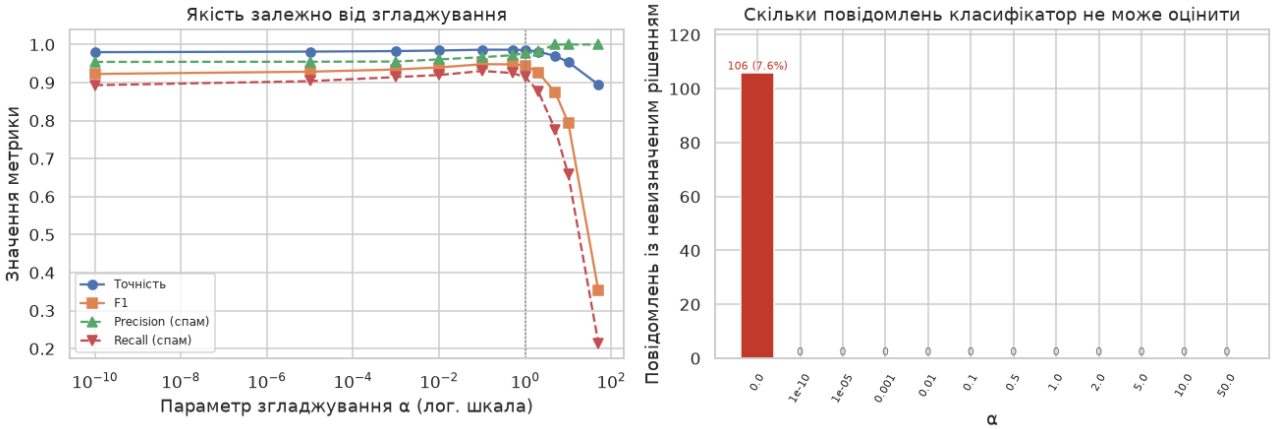


Рисунок 2: Вплив згладжування

З таблиці видно три речі. Згладжування дає приріст F1 на 13.4 пункта (0.8146 → 0.9482), і це найбільший ефект серед усіх параметрів методу. Далі, достатньо зробити ймовірність просто ненульовою: вже за $\alpha = 10^{-10}$ невизначених випадків немає, а F1 зростає до 0.9227. Основна шкода походить не від неточності оцінки, а саме від множення на нуль. По-третє, надмірне згладжування шкодить по-іншому: за $\alpha \geq 5$ precision сягає 1.0000, але recall падає

до 0.21. Псевдовідліки розмивають різницю між класами, свідчення слів слабшають, і модель дедалі частіше покладається на апріорну ймовірність, а вона на боці `ham` (86.6 %). Фільтр стає настільки обережним, що майже не помиляється лише тому, що майже нічого не блокує.

Оптимальне значення $\alpha = 0.1$, тобто менше за класичну одиницю Лапласа.

3.3 Різновиди наївного Баєса

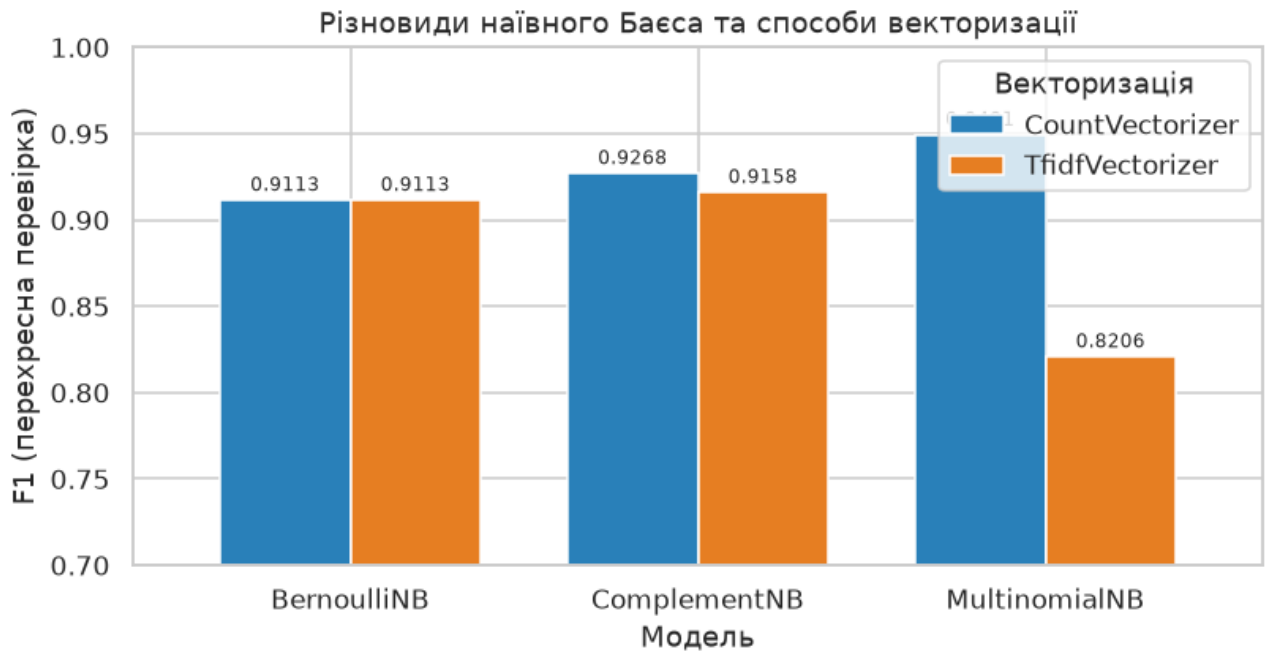


Рисунок 3: Різновиди NB

`MultinomialNB` враховує частоти слів, `BernoulliNB` лише факт наявності, `ComplementNB` розроблений для незбалансованих даних.

3.4 Найінформативніші слова

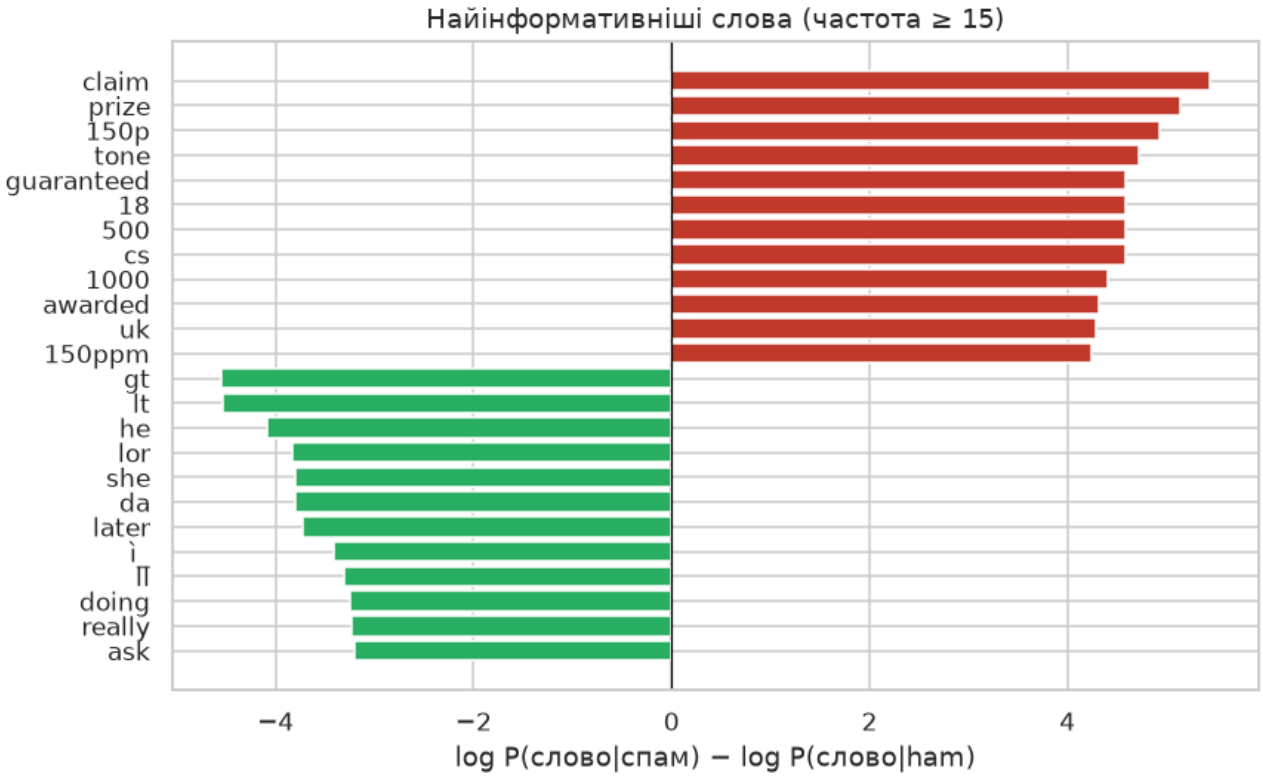


Рисунок 4: Індикативні слова

Модель відновлює зрозумілі людині ознаки спаму: згадки про виграші, безкоштовні пропозиції, короткі номери та заклики надіслати повідомлення.

4 Результати

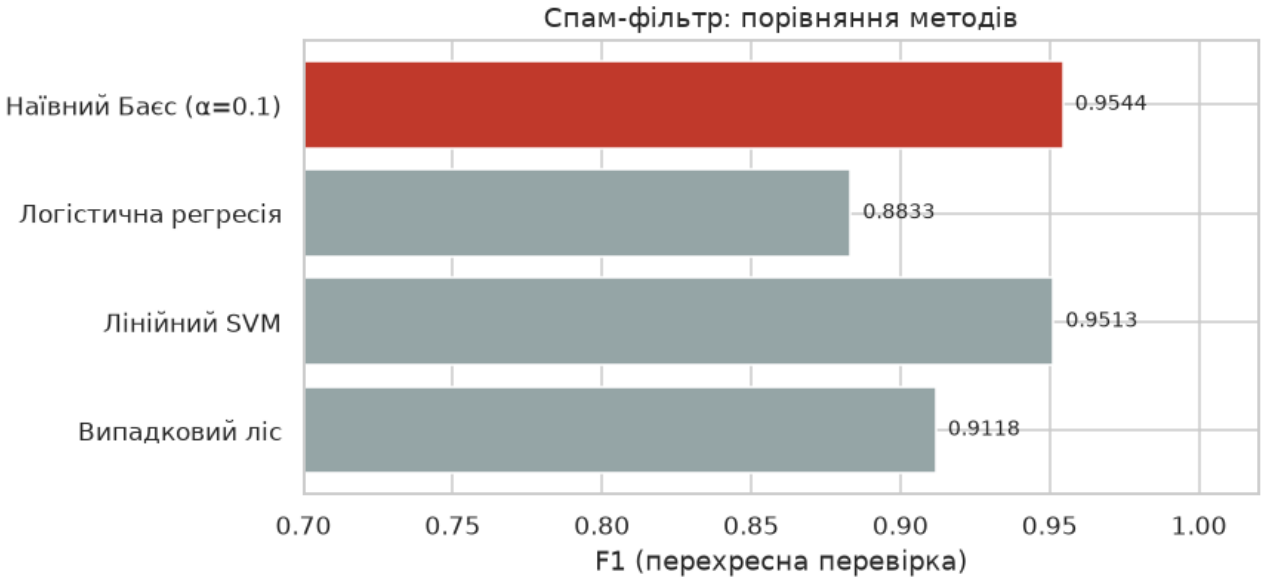


Рисунок 5: Порівняння методів

Модель	F1 (CV)	Точність	Precision (спам)	Recall (спам)
Наївний Баєс (α = 0.1)	0.9544	0.9864	0.9667	0.9305
Лінійний SVM	0.9513	0.9864	0.9884	0.9091
Випадковий ліс	0.9118	0.9698	1.0000	0.7754
Логістична регресія	0.8833	0.9713	0.9933	0.7914

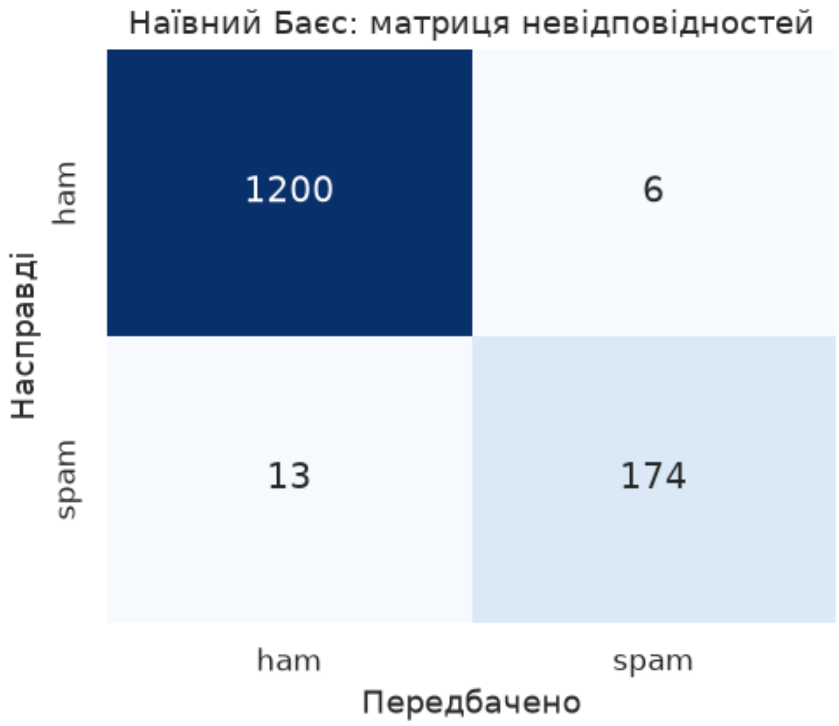


Рисунок 6: Матриця невідповідностей

На тестовій вибірці підсумкова модель дала 6 хибнопозитивних (заблоковане нормальне повідомлення) і 13 хибнонегативних (спам у скриньці).

5 Аналіз

Наївний Баєс тут виграв, і це вперше за чотири практичні роботи. У заняттях № 2 і № 3 на табличних даних перемагали дерева, а SVM відставав. На тексті ситуація протилежна: NB дає F1 = 0.9544 проти 0.9513 у лінійного SVM і 0.9118 у випадкового лісу.

Причина в природі задачі. Ознаки тут це тисячі розріджених лічильників слів, де кожне окреме слово дає слабке, але відносно незалежне свідчення. Наївний Баєс саме на це і розрахований: він множить свідчення, не намагаючись моделювати взаємодії між ознаками. Дерево ж будує розбиття по одній ознаці за раз і на розрідженому семитисячовимірному просторі працює погано, що видно з результату (0.9118 при найгіршому recall 0.7754).

Хибне припущення незалежності при цьому не заважає. Слова в реченні очевидно корелюють, проте метод дає найкращий результат. Справа в тому, що для класифікації важливий не точний рівень імовірності, а лише те, який клас набирає більше, а порядок класів зберігається навіть за спотворених абсолютних значень.

Компроміс precision/recall є практичним питанням, а не лише метричним. Для спам-фільтра заблоковане нормальне повідомлення гірше за пропущений спам. Випадковий ліс дає precision = 1.0000, тобто жодного хибного блокування, але пропускає 22 % спаму. Наївний Баєс за $\alpha = 0.1$ дає збалансованіший результат. Якщо потрібна максимальна безпечність, збільшення α дозволяє плавно зсуватись у бік precision: таблиця згладжування фактично є

шкалою цього компромісу.

6 Висновки

1. Спам-фільтр на основі наївного байєсівського класифікатора реалізовано. Найкраща конфігурація, `MultinomialNB` з $\alpha = 0.1$ на частотах слів, дала F1 = 0.9544 і точність 0.9864 за частки спаму 13.4 %.
2. Проблему нульової ймовірності досліджено кількісно. 88.2 % словника становлять слова, присутні лише в одному класі; без згладжування 7.6 % тестових повідомлень отримують нульову ймовірність для обох класів, і рішення стає неможливим.
3. Згладжування дає +13.4 пункта F1 (0.8146 $\rightarrow$ 0.9482) і є найвпливовішим параметром методу. Основний виграш дає сам факт ненульовості: вже за $\alpha = 10^{-10}$ F1 зростає до 0.9227.
4. Надмірне згладжування шкодить симетрично: за $\alpha \geq 5$ precision сягає 1.0, але recall падає до 0.21, бо псевдовідліки розмивають свідчення слів і модель покладається на апріорну ймовірність більшості.
5. На текстових даних наївний Баєс перевершує дерева та SVM, на відміну від табличних задач практичних занять № 2 і № 3. Розріджені лічильники слів з численними слабкими відносно незалежними свідченнями відповідають саме тій моделі, яку припускає метод.
6. Обчислення слід виконувати в логарифмах: добуток сотень імовірностей інакше спричиняє машинне зникнення порядку.

7 Джерела

1. Ham & Spam Messages Dataset. URL: https://www.kaggle.com/datasets/muhammadahmedansari/ham-spam-messages-dataset
2. Almeida T., Gómez Hidalgo J., Yamakami A. Contributions to the Study of SMS Spam Filtering // ACM DOCENG. 2011.
3. Manning C., Raghavan P., Schütze H. Introduction to Information Retrieval. Ch. 13: Text classification and Naive Bayes. Cambridge University Press, 2008.
4. Scikit-learn: Naive Bayes. URL: https://scikit-learn.org/stable/modules/naive_bayes.html