МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

ЗВІТ

з дисципліни «Аналіз кіберінцидентів»

Практичне заняття № 4 — Наївний байєсівський класифікатор

Виконав: Вовкотруб Олександр Віталійович
Група: ФБ-61мн

Перевірив: Наконечна Юлія Володимирівна

Київ — 2026

Зміст

1 Мета роботи **2**

2 Постановка задачі **2**

3 Хід виконання **2**

3.1 Векторизація 2

3.2 Дослідження проблеми нульової ймовірності 3

3.2.1 Масштаб проблеми 3

3.2.2 Наслідки на тестовій вибірці 3

3.2.3 Конкретний приклад 3

3.2.4 Згладжування Лапласа 4

3.3 Різновиди наївного Баєса 5

3.4 Найінформативніші слова 6

4 Результати **7**

5 Аналіз **8**

6 Висновки **9**

7 Джерела **9**

1 Мета роботи

Створити спам-фільтр на основі наївного байєсівського класифікатора та дослідити проблему нульової ймовірності — головну вразливість цього алгоритму.

2 Постановка задачі

Використано датасет **SMS Spam Collection** (UCI) — 5 572 SMS-повідомлення англійською, з них 747 спаму (13.4 %) і 4 825 звичайних (`ham`).

За теоремою Баєса ймовірність належності повідомлення до класу c за умови спостереження слів $w_1 \dots w_n$ пропорційна $P(c) \cdot P(w_1 \dots w_n \mid c)$. Класифікатор називається **наївним**, бо припускає умовну незалежність слів:

$$P(w_1 \dots w_n \mid c) \approx \prod_{i=1}^{n} P(w_i \mid c)$$

Для природної мови це припущення явно хибне — слова корелюють, — але на практиці метод працює добре.

Позитивною подією вважаємо **спам**. Хибнопозитивне спрацювання (блокування нормального повідомлення) для користувача гірше за пропущений спам, тому окрема увага приділена precision.

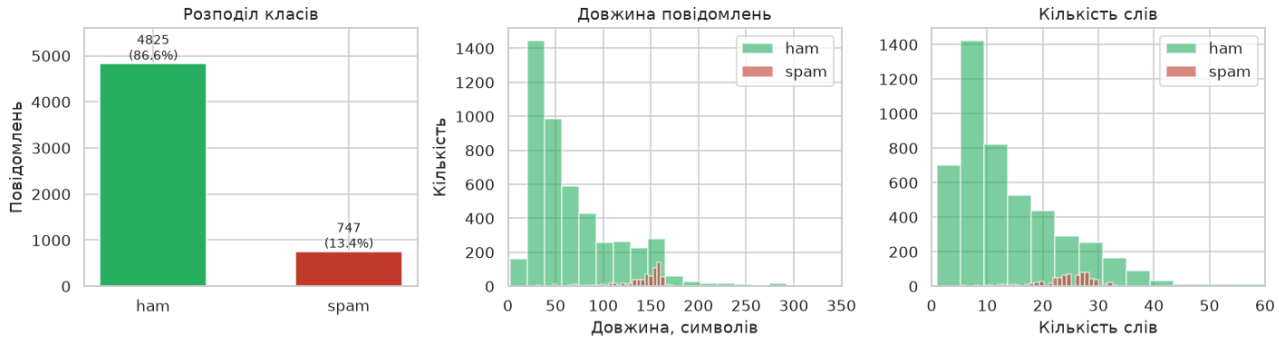


Рисунок 1: Огляд датасету

3 Хід виконання

3.1 Векторизація

`CountVectorizer` будує словник **за навчальною вибіркою** і перетворює кожне повідомлення на вектор частот слів. Розмір словника — 7 534 слова, матриця ознак заповнена на 0.18 %.

Саме те, що словник будується лише за навчальними даними, і породжує проблему нульової ймовірності: у тестових повідомленнях неминуче з’являються слова, яких модель не бачила.

3.2 Дослідження проблеми нульової ймовірності

Оцінка ймовірності слова є частотною:

$$P(w_i \mid c) = \frac{\text{count}(w_i, c)}{\sum_w \text{count}(w, c)}$$

Якщо слово жодного разу не зустрілось у документах класу c, то $P(w_i \mid c) = 0$, і **весь добуток обертається на нуль** незалежно від решти слів. Одне незнайоме слово анулює всі інші свідчення.

3.2.1 Масштаб проблеми

Показник	Значення
Слів у словнику	7 534
Зустрічаються **тільки** в `ham`	5 052 (67.1 %)
Зустрічаються **тільки** в `spam`	1 594 (21.2 %)
Разом «однокласових» слів	**6 646 (88.2 %)**

Для 88 % словника одна з умовних імовірностей дорівнює нулю ще до того, як класифікатор побачив тестові дані.

3.2.2 Наслідки на тестовій вибірці

Реалізовано власний наївний Баєс з керованим згладжуванням — щоб побачити механізм, а не лише результат бібліотеки. Обчислення виконуються в логарифмах: добуток сотень імовірностей інакше спричиняє машинне зникнення порядку (underflow).

Без згладжування ($\alpha = 0$) на 1 393 тестових повідомленнях:

Ситуація	Повідомлень
$\log P(\text{spam} \mid d) = -\infty$	1 153
$\log P(\text{ham} \mid d) = -\infty$	238
Обидві $-\infty$ — рішення неможливе	**106 (7.6 %)**

Для 7.6 % повідомлень класифікатор без згладжування не може ухвалити рішення взагалі: обидва добутки нульові, і вибір вироджується у значення за замовчуванням.

3.2.3 Конкретний приклад

```
Hi babe its Jordan, how r u? Im home from abroad and lonely, text me
back if u    wanna chat xxSP visionsms.com Text stop to stopCost 150p
08712400603
```

Це справжній спам. Але:

- слово `lonely` не зустрічалось у навчальному спамі → $P(\text{lonely} \mid \text{spam}) = 0$;
- слова `150p`, `jordan`, `visionsms` не зустрічались у навчальному `ham` → $P(\cdot \mid \text{ham}) = 0$.

Обидва добутки перетворюються на нуль, і повідомлення стає нерозпізнаваним — попри те, що `visionsms` і `150p` є очевидними ознаками спаму.

3.2.4 Згладжування Лапласа

Проблема усувається додаванням псевдовідліку α:

$$P(w_i \mid c) = \frac{\text{count}(w_i, c) + \alpha}{\sum_w \text{count}(w, c) + \alpha \cdot |V|}$$

За $\alpha = 1$ це класичне згладжування Лапласа, за $0 < \alpha < 1$ — згладжування Лідстоуна.

α	Невизначених	Точність	Precision	Recall	F1
0	**106**	0.9562	0.9437	0.7166	**0.8146**
10^{-10}	0	0.9799	0.9543	0.8930	0.9227
0.01	0	0.9842	0.9609	0.9198	0.9399
0.1	0	0.9864	0.9667	0.9305	**0.9482**
1.0	0	0.9856	0.9771	0.9144	0.9448
5.0	0	0.9698	**1.0000**	0.7754	0.8735
50.0	0	0.8945	**1.0000**	0.2139	0.3524

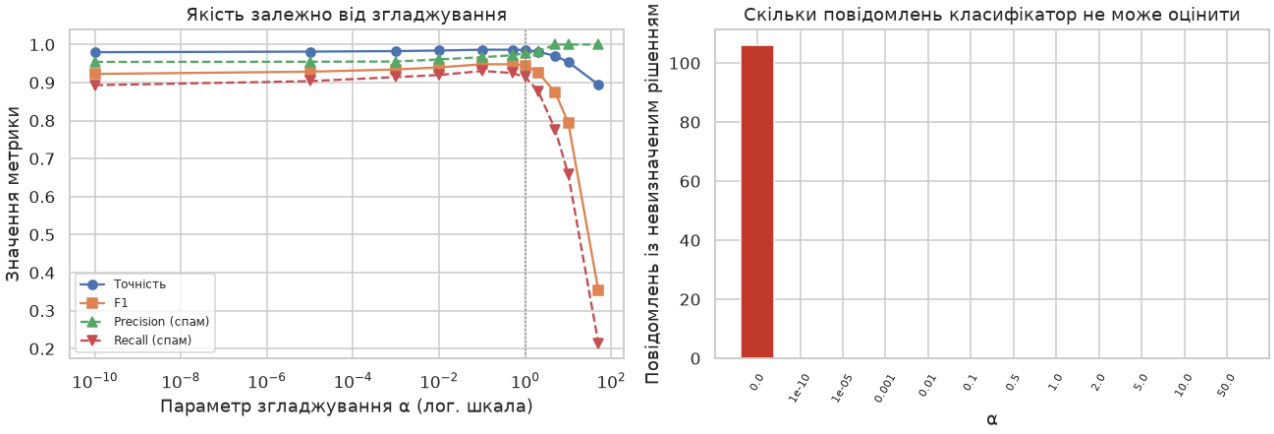


Рисунок 2: Вплив згладжування

Три спостереження.

По-перше, згладжування дає **+13.4 пункта F1** (0.8146 → 0.9482). Це найбільший ефект серед усіх параметрів методу.

По-друге, достатньо зробити ймовірність просто ненульовою: вже за $\alpha = 10^{-10}$ невизначених випадків немає, а F1 підскакує до 0.9227. Тобто основна шкода походить не від неточності оцінки, а саме від множення на нуль.

По-третє, надмірне згладжування шкідливе інакше: за $\alpha \geq 5$ precision сягає 1.0000, але recall падає до 0.21. Псевдовідліки розмивають різницю між класами, свідчення слів слабшають, і модель дедалі частіше покладається на апріорну ймовірність — а вона на боці `ham` (86.6 %). Фільтр стає «обережним» до марності: він майже не помиляється, бо майже нічого не блокує.

Оптимум — $\alpha = 0.1$, менший за класичну одиницю Лапласа.

3.3 Різновиди наївного Баєса

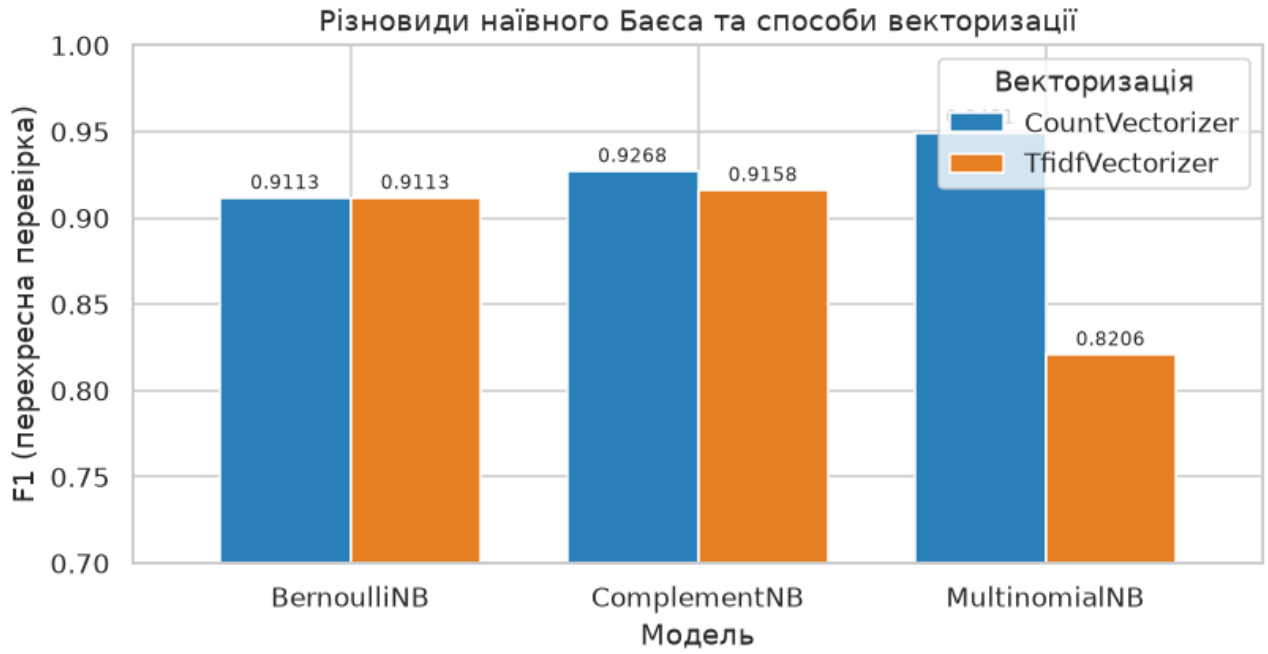


Рисунок 3: Різновиди NB

`MultinomialNB` враховує частоти слів, `BernoulliNB` — лише факт наявності, `ComplementNB` розроблений для незбалансованих даних.

3.4 Найінформативніші слова

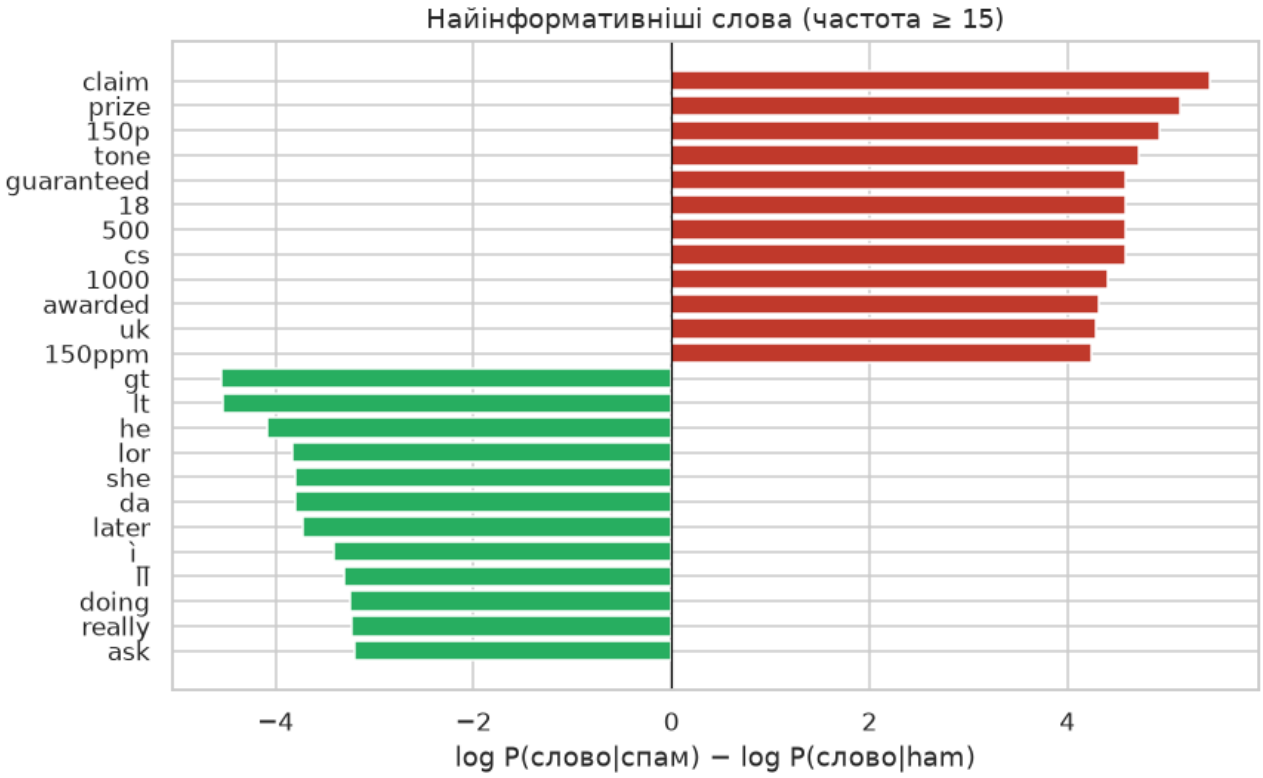


Рисунок 4: Індикативні слова

Модель відновлює зрозумілі людині ознаки спаму — згадки про виграші, безкоштовні пропозиції, короткі номери та заклики надіслати повідомлення.

4 Результати

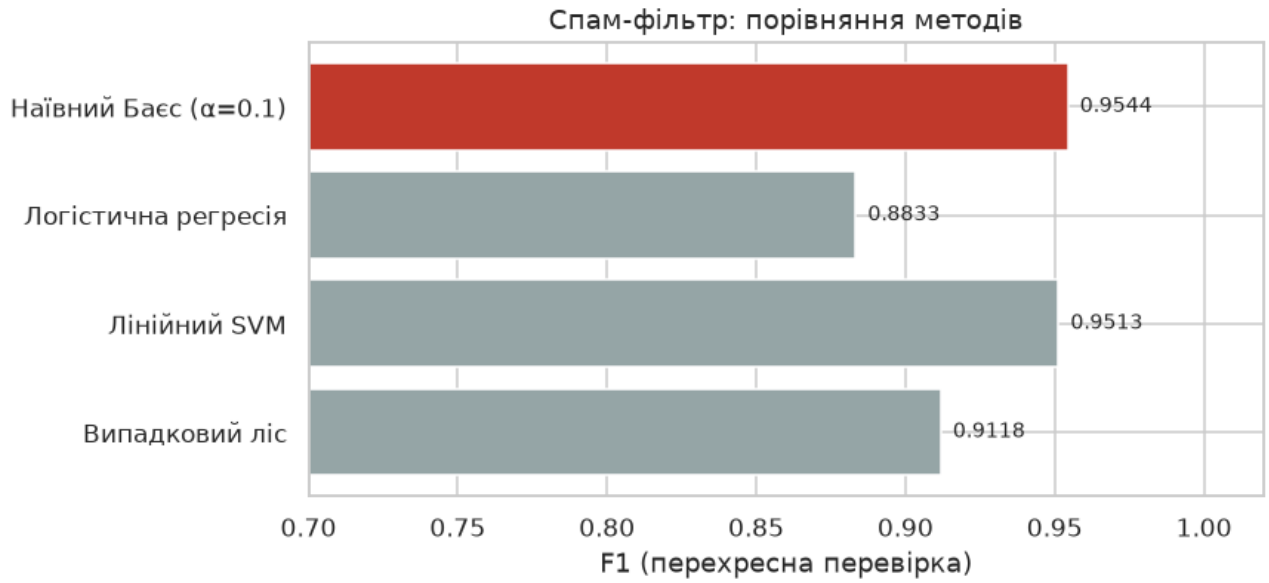


Рисунок 5: Порівняння методів

Модель	F1 (CV)	Точність	Precision (спам)	Recall (спам)
Наївний Баєс (α = 0.1)	**0.9544**	0.9864	0.9667	**0.9305**
Лінійний SVM	0.9513	0.9864	0.9884	0.9091
Випадковий ліс	0.9118	0.9698	**1.0000**	0.7754
Логістична регресія	0.8833	0.9713	0.9933	0.7914

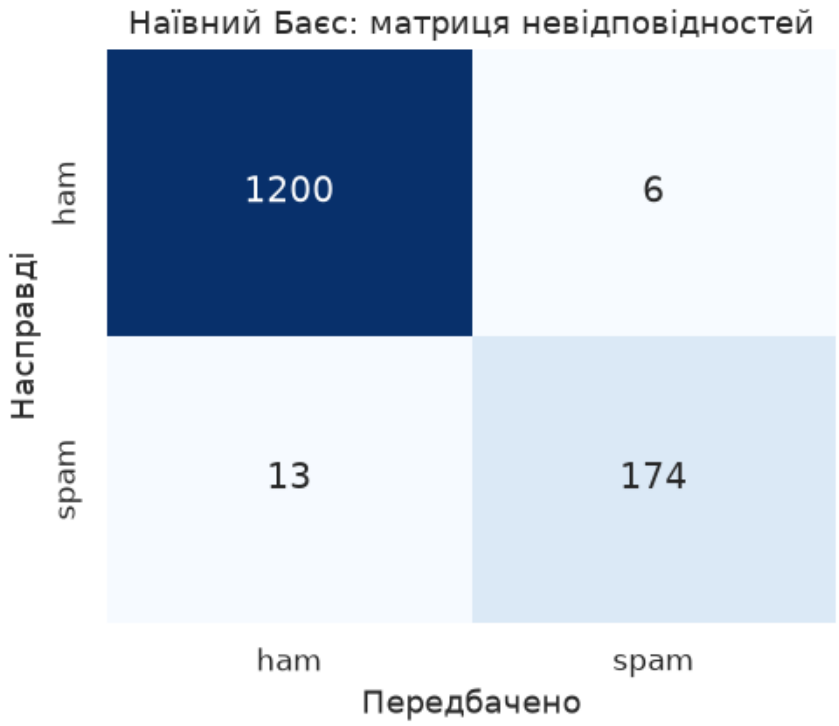


Рисунок 6: Матриця невідповідностей

На тестовій вибірці підсумкова модель дала 6 хибнопозитивних (заблоковане нормальне повідомлення) і 13 хибнонегативних (спам у скриньці).

5 Аналіз

Наївний Баєс тут виграє — уперше за чотири практичні роботи. У практичних заняттях № 2 і № 3 на табличних даних перемагали дерева, а SVM відставав. На тексті ситуація протилежна: NB дає F1 = 0.9544 проти 0.9513 у лінійного SVM і 0.9118 у випадкового лісу.

Причина в природі задачі. Ознаки тут — тисячі розріджених лічильників слів, де кожне окреме слово дає слабке, але незалежне свідчення. Наївний Баєс саме на це й розрахований: він множить свідчення, не намагаючись моделювати взаємодії між ознаками. Дерево ж будує розбиття по одній ознаці за раз і на розрідженому семитисячовимірному просторі працює погано, що й видно з результату (0.9118 при найгіршому recall 0.7754).

Хибне припущення незалежності не заважає. Слова в реченні очевидно корелюють, проте метод дає найкращий результат. Причина в тому, що для класифікації важливий не точний рівень імовірності, а лише те, який клас набирає більше — а порядок класів зберігається навіть за спотворених абсолютних значень.

Компроміс precision/recall є практичним питанням, а не лише метричним. Для спам-фільтра заблоковане нормальне повідомлення гірше за пропущений спам. Випадковий ліс дає precision = 1.0000, тобто жодного хибного блокування, але пропускає 22 % спаму. Наївний Баєс за $\alpha = 0.1$ дає збалансованіший результат. Якщо потрібна максимальна безпечність, збільшення α дозволяє плавно рухатись у бік precision — таблиця згладжування фактично є

шкалою цього компромісу.

6 Висновки

1. Спам-фільтр на основі наївного байєсівського класифікатора реалізовано; найкраща конфігурація — `MultinomialNB` з $\alpha = 0.1$ на частотах слів — дала F1 = 0.9544 і точність 0.9864 за частки спаму 13.4 %.
2. Проблема нульової ймовірності досліджена кількісно. 88.2 % словника становлять слова, присутні лише в одному класі; без згладжування 7.6 % тестових повідомлень отримують нульову ймовірність для обох класів, і рішення стає неможливим.
3. **Згладжування дає +13.4 пункта F1** (0.8146 $\rightarrow$ 0.9482) і є найвпливовішим параметром методу. Причому основний виграш дає сам факт ненульовості: вже за $\alpha = 10^{-10}$ F1 зростає до 0.9227.
4. Надмірне згладжування шкодить симетрично: за $\alpha \geq 5$ precision сягає 1.0, але recall падає до 0.21, бо псевдовідліки розмивають свідчення слів і модель покладається на апріорну ймовірність більшості.
5. На текстових даних наївний Баєс перевершує дерева та SVM — на відміну від табличних задач практичних занять № 2 і № 3. Розріджені лічильники слів з численними слабкими незалежними свідченнями відповідають саме тій моделі, яку припускає метод.
6. Обчислення слід виконувати в логарифмах: добуток сотень імовірностей інакше спричиняє машинне зникнення порядку.

7 Джерела

1. Ham & Spam Messages Dataset. URL: https://www.kaggle.com/datasets/muhammadahmedansari/ham-spam-messages-dataset
2. Almeida T., Gómez Hidalgo J., Yamakami A. Contributions to the Study of SMS Spam Filtering // ACM DOCENG. 2011.
3. Manning C., Raghavan P., Schütze H. Introduction to Information Retrieval. Ch. 13: Text classification and Naive Bayes. Cambridge University Press, 2008.
4. Scikit-learn: Naive Bayes. URL: https://scikit-learn.org/stable/modules/naive_bayes.html