МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

ЗВІТ

з дисципліни «Аналіз кіберінцидентів»

Практичне заняття № 5 — Метод K-найближчих сусідів

Виконав: Вовкотруб Олександр Віталійович
Група: ФБ-61мн

Перевірив: Наконечна Юлія Володимирівна

Київ — 2026

Зміст

1 Мета роботи **2**

2 Постановка задачі **2**

3 Хід виконання **2**

3.1 Особливість № 1: масштаб ознак і несподіваний результат 2

3.2 Метрика відстані 3

3.3 Особливість № 2: оптимальне k = 1 4

3.4 Особливість № 3: прокляття розмірності 4

3.5 Особливість № 4: щільність вибірки та вартість передбачення 5

4 Результати **7**

5 Аналіз **8**

5.1 Переваги методу 8

5.2 Недоліки методу 8

5.3 Порівняння з іншими методами 9

6 Висновки **9**

7 Джерела **10**

1 Мета роботи

Реалізувати алгоритм K-найближчих сусідів, визначити його переваги та недоліки і дослідити залежність точності алгоритму від особливостей використаного датасету.

2 Постановка задачі

Використано датасет UGRansome, той самий, що в практичних заняттях № 2 і № 3, і ту саму підвибірку 30 000 записів з тим самим зерном, що в занятті № 3. Це робить результати прямо порівнянними з деревом, лісом, SVM і логістичною регресією.

kNN не має етапу навчання у звичайному розумінні: він запам'ятовує навчальну вибірку, а для класифікації нового об'єкта знаходить k найближчих прикладів і повертає клас більшості. Через це метод називають лінивим (lazy learning). Обчислення переносяться з навчання на передбачення, і це визначає більшість його переваг та недоліків.

Досліджувані особливості даних: масштаб ознак, розмірність простору, наявність нерелевантних ознак, щільність вибірки.

3 Хід виконання

3.1 Особливість № 1: масштаб ознак і несподіваний результат

kNN, як і SVM, ухвалює рішення за відстанями, тож теорія однозначно радить масштабувати ознаки. У практичному занятті № 3 масштабування дало SVM +32 пункти. Тут результат виявився протилежним.

k	Без масштабування	StandardScaler	Різниця
1	0.9660	0.9703	+0.0044
5	0.9710	0.9629	−0.0081
15	0.9641	0.9497	−0.0144
30	0.9508	0.9368	−0.0140

Ефект стійкий (стандартні відхилення 0.0005–0.0014, тобто різниця сягає кількох стандартних відхилень) і залежить від k: за $k = 1$ масштабування трохи допомагає, за більших значень шкодить, виходячи на насичення близько −0.014. Шкода не зростає безмежно, а впирається в стелю: щойно внесок ознаки `USD` розмито, далі розмивати нічого.

Причина з'ясовується зіставленням важливості ознак з їхнім розмахом:

Ознака	Важливість	Розмах
`USD`	0.2407	126 378
`BTC`	0.1401	1 979

Ознака	Важливість	Розмах
`Flag`	0.1300	8
`ExpAddress`	0.1052	6
`Clusters`	0.0900	11

`USD` є водночас найінформативнішою ознакою і найширшою за розмахом. Без масштабування евклідова відстань визначається майже виключно нею, тобто дані випадково отримують саме те зважування ознак, яке й потрібно. `StandardScaler` зрівнює `USD` з малоінформативними категоріальними кодами і тим розмиває сигнал. Що більше k, то по ширшому околу усереднюється рішення і то сильніше шкодить це розмиття.

З цього випливає висновок: масштабування корисне не саме по собі, а тоді, коли розмах ознаки не корелює з її інформативністю. Це властивість конкретних даних, а не універсальне правило.

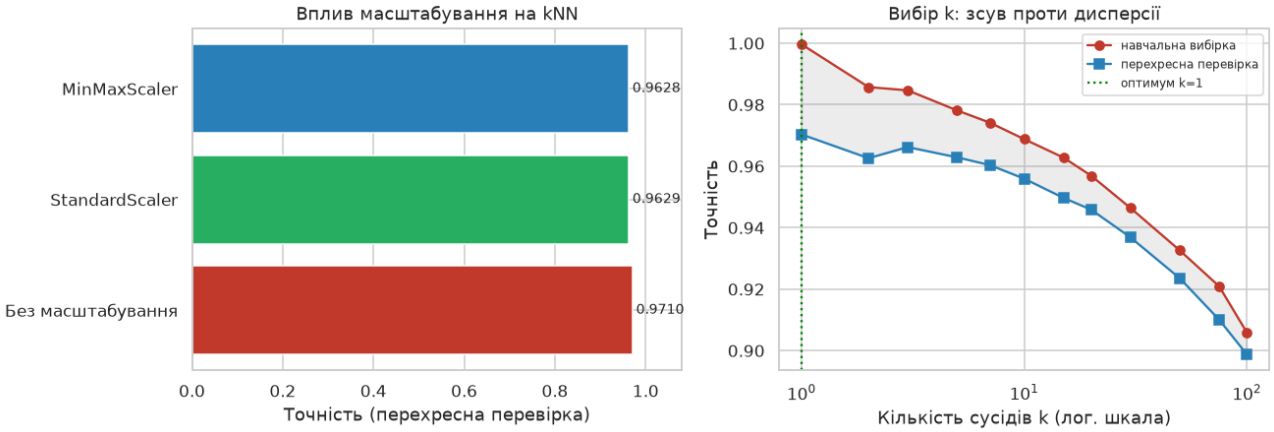


Рисунок 1: Масштабування та вибір k

3.2 Метрика відстані

Метрика	Точність	Вагування за відстанню
Манхеттенська ($p = 1$)	0.9743	0.9743
Евклідова ($p = 2$)	0.9703	0.9703
Чебишевська ($p = \infty$)	0.9644	0.9644

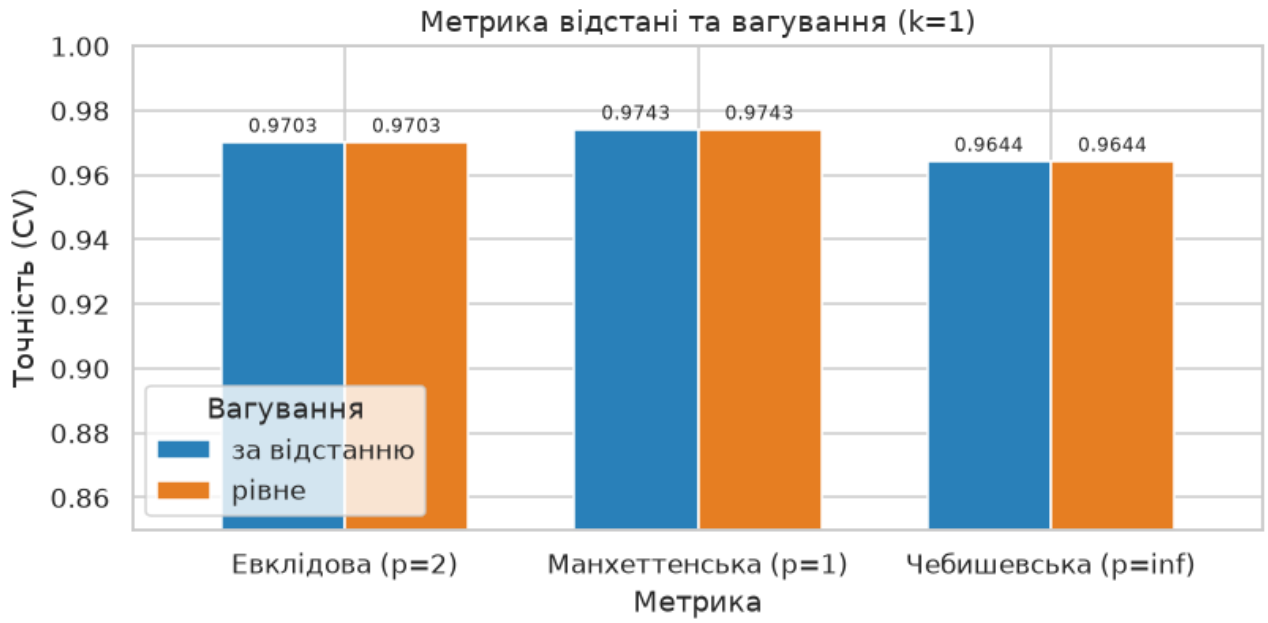


Рисунок 2: Метрики відстані та вагування

Манхеттенська метрика дала найкращий результат роботи, 0.9743, на 0.4 пункта краще за евклідову і, що важливіше, краще за SVM з практичного заняття № 3 (0.9727). Це типово для просторів помірної розмірності: сума модулів менш чутлива до окремої великої різниці за однією координатою, ніж сума квадратів.

За $k = 1$ вагування за відстанню не має ефекту, бо зважувати один голос немає сенсу, тому обидва стовпці збігаються до останнього знака.

3.3 Особливість № 2: оптимальне k = 1

Зазвичай $k = 1$ вважають ознакою перенавчання: клас визначає єдиний найближчий приклад, модель ідеально відтворює навчальну вибірку і вкрай чутлива до шуму. Тут же саме $k = 1$ дає найкращий результат серед усіх k: 0.9703 за евклідової метрики (з манхеттенською 0.9743, див. вище).

Це узгоджується з висновком практичного заняття № 2 про те, що UGRansome майже детермінований і не містить шуму. Там це проявилося в тому, що випадковий ліс не дав переваги над одним деревом (різниця −0.0009), а керований експеримент показав, що перевага ансамблю з'являється лише зі штучно доданим шумом.

Той самий факт пояснює і результат тут: якщо шуму немає, найближчий сусід і є правильною відповіддю, а усереднення по $k > 1$ лише втягує в рішення чужі приклади. Дві різні роботи незалежно виміряли одну й ту саму властивість даних.

3.4 Особливість № 3: прокляття розмірності

Головна слабкість kNN. У просторі високої розмірності відстані концентруються: різниця між найближчим і найдальшим сусідом стає відносно малою, і поняття близькості втрачає сенс.

Перевірено прямо: до даних додавались випадкові ознаки без жодної інформації.

Шумових ознак	Всього ознак	kNN	Випадковий ліс	Втрата kNN	min/max відстані
0	13	0.9492	0.9828	—	0.0001
10	23	0.8258	0.9682	−0.1234	0.0812
50	63	0.6102	0.9567	−0.3390	0.2969
200	213	0.4659	0.9343	−0.4833	0.5447

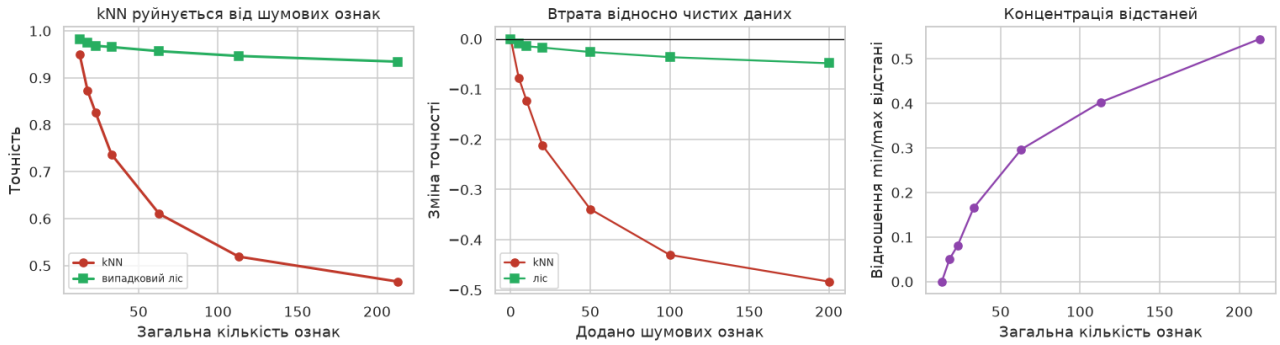


Рисунок 3: Прокляття розмірності

Двісті нерелевантних ознак відбирають у kNN 48 пунктів точності: метод падає майже до рівня випадкового вгадування. Випадковий ліс на тих самих даних втрачає лише 4.9 пункта, бо здатен нерелевантні ознаки просто не обирати для розбиття.

Третій стовпець вимірює механізм безпосередньо: відношення мінімальної відстані між точками до максимальної зростає з 0.0001 до 0.5447. Найближчий і найдальший сусіди стають майже рівновіддаленими, і «найближчий» перестає щось означати.

3.5 Особливість № 4: щільність вибірки та вартість передбачення

Розмір вибірки	Точність	Навчання, мс	Передбачення, мс
1 000	0.908	1.6	5.7
10 000	0.949	15.2	48.8
40 000	0.977	76.0	268.4
80 000	0.981	145.5	493.2

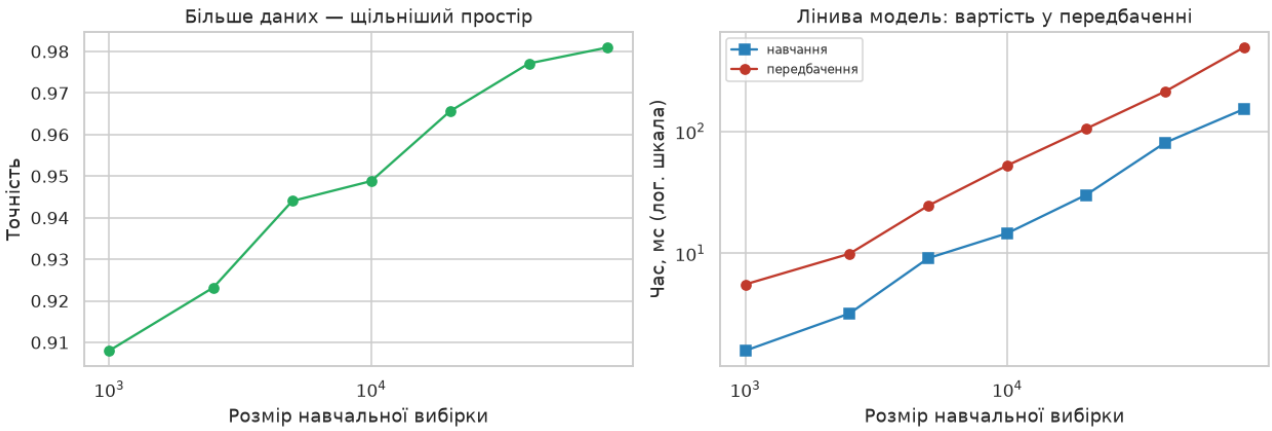


Рисунок 4: Лінива модель

Точність зростає з розміром вибірки монотонно і не виходить на плато: більше даних означає щільніший простір і ближчих сусідів. На повних 80 000 прикладів kNN дає 0.981, що помітно більше за 0.9703 на основній підвибірці.

Водночас передбачення коштує дорожче за навчання (493 мс проти 145 мс на 80 000). Варто зазначити, що на практиці «навчання» kNN у `scikit-learn` не є безкоштовним: бібліотека будує просторовий індекс, тож час навчання теж зростає з розміром даних. Класичне уявлення про нульову вартість навчання справедливе лише для реалізації повним перебором.

Окремий замір трьох структур пошуку на цих даних:

Структура	Навчання, с	Передбачення, с	Точність
`brute`	0.041	0.205	0.9731
`kd_tree`	0.052	0.145	0.9727
`ball_tree`	0.040	1.298	0.9727

За 13 вимірів KD-дерево виявилось найшвидшим, на 30 % швидшим за повний перебір, тоді як ball-дерево програє обом у 6–9 разів. Просторовий індекс тут окупається, але лише правильно дібраний: ball-дерево розраховане на високу розмірність і на такій задачі лише додає накладних витрат. Точність усіх трьох збігається з точністю до похибки розв’язання нічиїх.

4 Результати

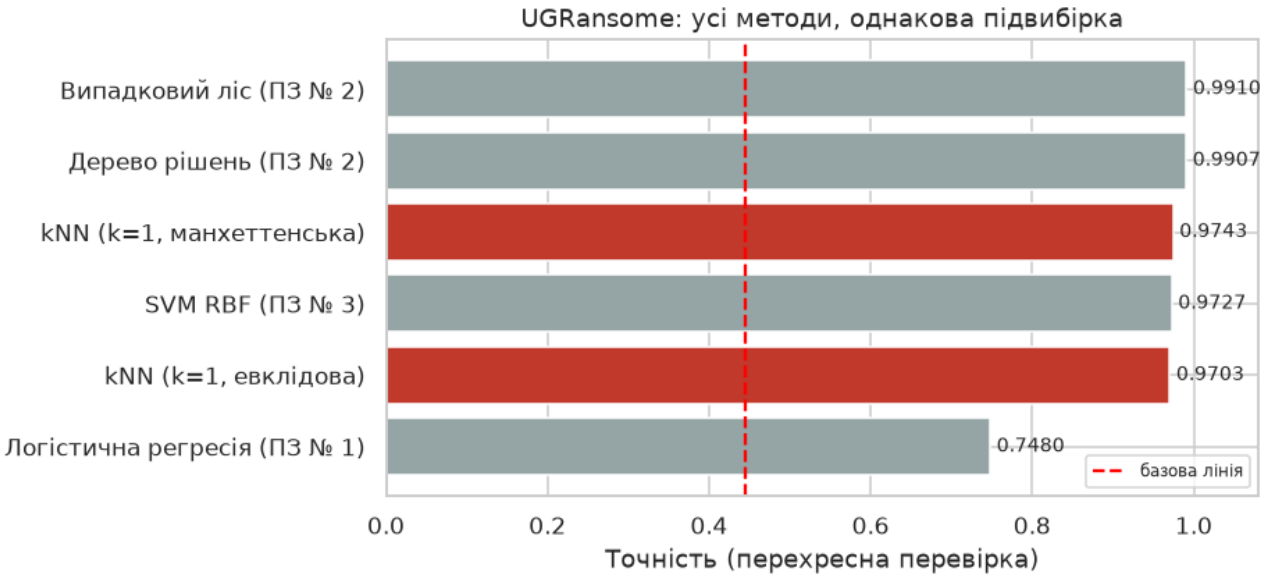


Рисунок 5: Порівняння методів

Модель	Точність (CV)	F1-macro
Випадковий ліс (ПЗ № 2)	0.9910	0.9914
Дерево рішень (ПЗ № 2)	0.9907	0.9905
SVM RBF (ПЗ № 3)	0.9727	0.9715
kNN (k = 1, манхеттенська)	0.9743	0.9757
kNN (k = 1, евклідова)	0.9703	0.9722
Логістична регресія	0.7480	0.7263

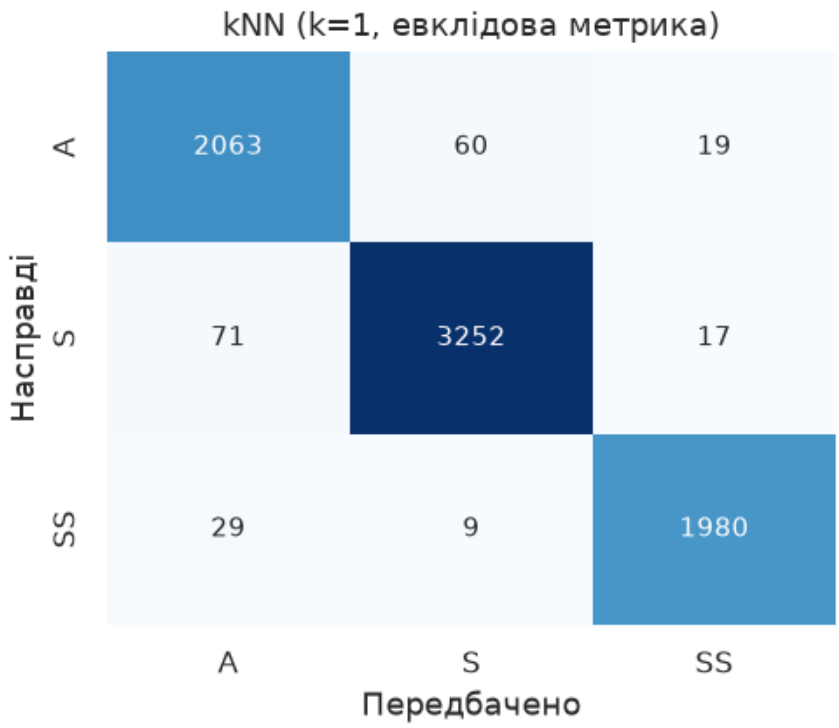


Рисунок 6: Матриця невідповідностей

Усі моделі в таблиці оцінено однаково, на тій самій підвибірці 30 000 записів із триблоковою перехресною перевіркою. Через це показники дерева й лісу нижчі за наведені в практичному занятті № 2 (0.9943 і 0.9934), де використано повний датасет і п’ять блоків; у межах цієї таблиці порівняння коректне.

5 Аналіз

5.1 Переваги методу

- Немає припущень про форму межі. kNN не вимагає, щоб класи розділялись гіперплощиною чи гладкою поверхнею; межа може бути якою завгодно складною.
- Тривіальне донавчання. Додати нові приклади означає просто дописати їх до вибірки, перенавчати нічого не треба. Для системи виявлення інцидентів, куди постійно надходять нові розмічені випадки, це практична перевага.
- Один зрозумілий параметр. На відміну від SVM з його `C` і `gamma`, тут налаштовується здебільшого k.
- Природна багатокласовість: голосування працює для будь-якої кількості класів без змін.

5.2 Недоліки методу

- Прокляття розмірності, критичний недолік: 200 нерелевантних ознак коштують 48 пунктів точності проти 4.9 у випадкового лісу.

- Вартість передбачення зростає з обсягом даних, тобто модель стає дедалі повільнішою саме тоді, коли вона стає точнішою.
- Потрібно зберігати всю навчальну вибірку: для 149 043 записів це вся таблиця в пам'яті, тоді як дерево займає 1 465 вузлів.
- Чутливість до масштабу, причому, як показано вище, у неочевидний бік.
- Немає інтерпретованої моделі: пояснення зводиться до «схожі приклади належали до цього класу», без правил, які можна прочитати.

5.3 Порівняння з іншими методами

kNN з евклідовою метрикою (0.9703) практично зрівнявся з SVM (0.9727), а з манхеттенською (0.9743) навіть трохи випередив його; деревам (0.991) поступились обидва варіанти. Причина та сама, що й у SVM: обидва методи спираються на відстані у неперервному просторі, а UGRansome складається переважно з категоріальних ознак, закодованих цілими числами. Таке кодування нав'язує категоріям неіснуючий порядок, і «відстань» між `Flag=2` і `Flag=5` не має змісту, тоді як дерево просто розділяє категорії розбиттями.

6 Висновки

1. Метод kNN реалізовано на датасеті UGRansome; найкраща конфігурація ($k = 1$, манхеттенська метрика, стандартизація) дала точність 0.9743 за базової лінії 0.4454; з евклідовою метрикою 0.9703 за F1-macro 0.9722.

2. Масштабування може шкодити. Всупереч загальному правилу, тут `StandardScaler` знижує точність (до −0.0144 за $k = 15$), бо найширша за розмахом ознака `USD` є водночас найінформативнішою, і нерівні масштаби випадково дають правильне зважування. Масштабування корисне тоді, коли розмах ознаки не корелює з її інформативністю.

3. Оптимальне $k = 1$ підтверджує висновок практичного заняття № 2 про відсутність шуму в UGRansome: якщо шуму немає, найближчий сусід і є відповіддю. Дві незалежні роботи виміряли одну властивість даних різними способами.

4. Прокляття розмірності підтверджено кількісно: 200 шумових ознак відбирають у kNN 48 пунктів точності проти 4.9 у випадкового лісу, а відношення min/max відстані зростає з 0.0001 до 0.5447, тобто поняття близькості вироджується.

5. Точність kNN зростає з обсягом даних монотонно (0.908 при 1 000 записів → 0.981 при 80 000) і не виходить на плато, але разом з нею зростає вартість передбачення.

6. На цьому датасеті kNN поступається деревам (0.9743 проти 0.9910) з тієї ж причини, що й SVM: методи, засновані на відстанях, погано працюють з категоріальними ознаками, закодованими цілими числами. kNN, однак, випереджає SVM: 0.9743 проти 0.9727.

7. Вибір структури пошуку не зводиться до «дерева проти перебору»: на 13 вимірах KD-дерево виявилось найшвидшим (0.145 с проти 0.205 с у повного перебору), тоді як ball-дерево програло обом у 6–9 разів. Індекс окупається, але лише дібраний під розмірність задачі.

7 Джерела

1. UGRansome dataset. URL: https://www.kaggle.com/datasets/nkongolo/ugransome-dataset
2. Cover T., Hart P. Nearest neighbor pattern classification // IEEE Transactions on Information Theory. 1967. Vol. 13. P. 21–27.
3. Beyer K. et al. When Is “Nearest Neighbor” Meaningful? // ICDT. 1999. P. 217–235.
4. Scikit-learn: Nearest Neighbors. URL: https://scikit-learn.org/stable/modules/neighbors.html