МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

ЗВІТ

з дисципліни «Аналіз кіберінцидентів»

Практичне заняття № 5 — Метод K-найближчих сусідів

Виконав: Вовкотруб Олександр Віталійович
Група: ФБ-61мн

Перевірив: Наконечна Юлія Володимирівна

Київ — 2026

Зміст

1 Мета роботи **2**

2 Постановка задачі **2**

3 Хід виконання **2**

3.1 Особливість № 1: масштаб ознак — і несподіваний результат 2

3.2 Метрика відстані 3

3.3 Особливість № 2: оптимальне k = 1 4

3.4 Особливість № 3: прокляття розмірності 4

3.5 Особливість № 4: щільність вибірки та вартість передбачення 5

4 Результати **7**

5 Аналіз **8**

5.1 Переваги методу 8

5.2 Недоліки методу 8

5.3 Порівняння з іншими методами 9

6 Висновки **9**

7 Джерела **10**

1 Мета роботи

Реалізувати алгоритм K-найближчих сусідів, визначити його переваги та недоліки і дослідити залежність точності алгоритму від особливостей використаного датасету.

2 Постановка задачі

Використано датасет **UGRansome** — той самий, що в практичних заняттях № 2 і № 3, і ту саму підвибірку 30 000 записів з тим самим зерном, що в занятті № 3. Це робить результати прямо порівнянними з деревом, лісом, SVM і логістичною регресією.

kNN не має етапу навчання у звичайному розумінні: він запам'ятовує навчальну вибірку, а для класифікації нового об'єкта знаходить k найближчих прикладів і повертає клас більшості. Через це метод називають **лінивим** (lazy learning). Обчислення переносяться з навчання на передбачення, і це визначає більшість його переваг та недоліків.

Досліджувані особливості даних: масштаб ознак, розмірність простору, наявність нерелевантних ознак, щільність вибірки.

3 Хід виконання

3.1 Особливість № 1: масштаб ознак — і несподіваний результат

kNN, як і SVM, ухвалює рішення за **відстанями**, тож теорія однозначно радить масштабувати ознаки. У практичному занятті № 3 масштабування дало SVM **+32 пункти**. Тут результат виявився протилежним.

k	Без масштабування	StandardScaler	Різниця
1	0.9660	0.9703	**+0.0044**
5	0.9710	0.9629	−0.0081
15	0.9641	0.9497	−0.0144
30	0.9508	0.9368	−0.0140

Ефект стійкий (стандартні відхилення 0.0005–0.0014, тобто різниця сягає кількох стандартних відхилень) і **залежить від** k: за $k = 1$ масштабування трохи допомагає, за більших — шкодить, виходячи на насичення близько −0.014. Тобто шкода не зростає безмежно, а впирається в стелю: щойно внесок ознаки `USD` розмито, далі розмивати нічого.

Причина з'ясовується із зіставлення важливості ознак з їхнім розмахом:

Ознака	Важливість	Розмах
`USD`	**0.2407**	**126 378**
`BTC`	0.1401	1 979

Ознака	Важливість	Розмах
`Flag`	0.1300	8
`ExpAddress`	0.1052	6
`Clusters`	0.0900	11

`USD` є **водночас найінформативнішою ознакою і найширшою за розмахом**. Без масштабування евклідова відстань визначається майже виключно нею — тобто дані випадково отримують саме те зважування ознак, яке й потрібне. `StandardScaler` зрівнює `USD` з малоінформативними категоріальними кодами і тим розмиває сигнал. Що більше k, то по ширшому околу усереднюється рішення і то сильніше шкодить це розмиття.

Висновок, який варто запам'ятати: масштабування корисне не саме по собі, а тоді, коли розмах ознаки не корелює з її інформативністю. Це властивість конкретних даних, а не універсальне правило.

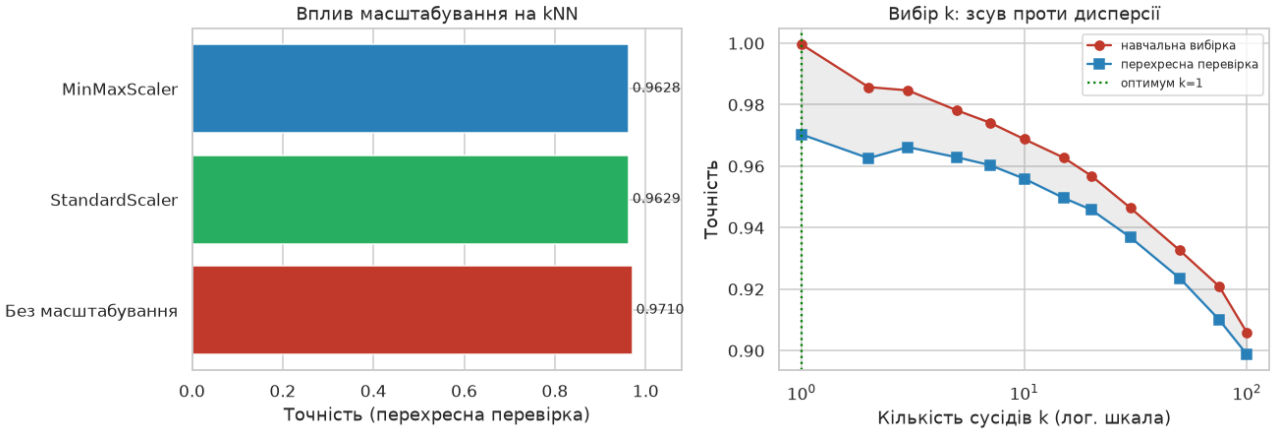


Рисунок 1: Масштабування та вибір k

3.2 Метрика відстані

Метрика	Точність	Вагування за відстанню
Манхеттенська ($p = 1$)	**0.9743**	0.9743
Евклідова ($p = 2$)	0.9703	0.9703
Чебишевська ($p = \infty$)	0.9644	0.9644

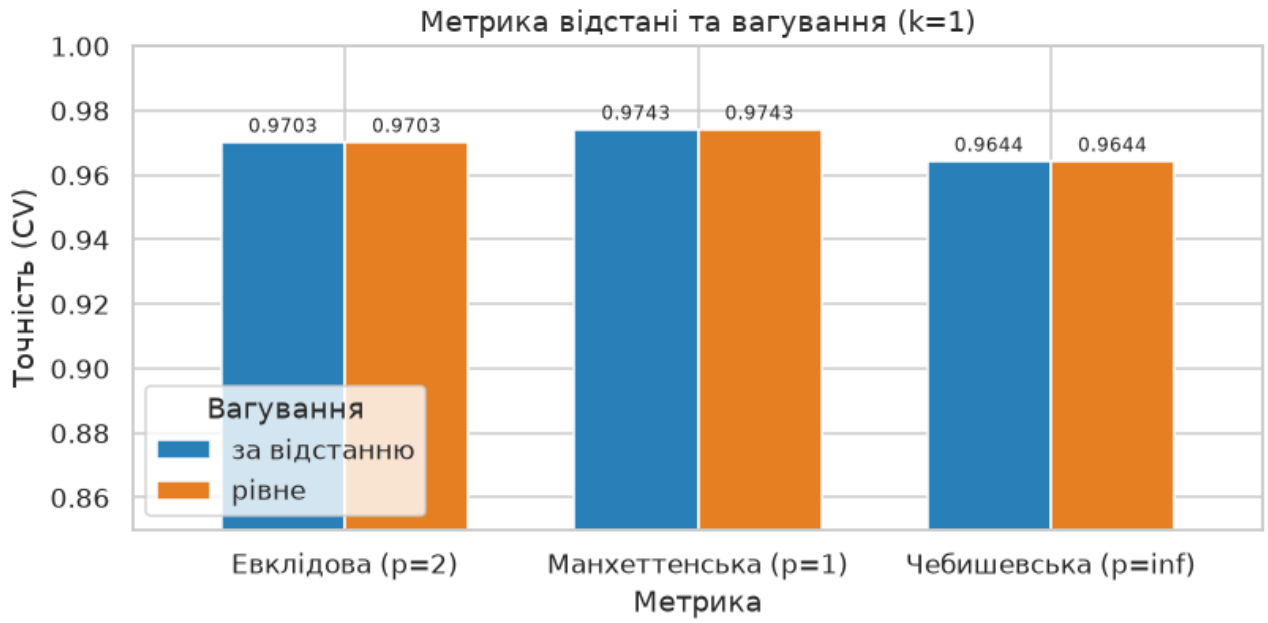


Рисунок 2: Метрики відстані та вагування

Манхеттенська метрика дає **найкращий результат роботи — 0.9743**, на 0.4 пункта краще за евклідову і, що важливіше, краще за SVM з практичного заняття № 3 (0.9727). Це типово для просторів помірної розмірності: сума модулів менш чутлива до окремої великої різниці за однією координатою, ніж сума квадратів.

За $k = 1$ вагування за відстанню не має ефекту — зважувати один голос немає сенсу, — тому обидва стовпці збігаються до останнього знака.

3.3 Особливість № 2: оптимальне k = 1

Зазвичай $k = 1$ вважають ознакою перенавчання: клас визначає єдиний найближчий приклад, модель ідеально відтворює навчальну вибірку і вкрай чутлива до шуму. Тут же саме $k = 1$ дає найкращий результат серед усіх k — 0.9703 за евклідової метрики (з манхеттенською — 0.9743, див. вище).

Це узгоджується з висновком практичного заняття № 2: **UGRansome майже детермінований і не містить шуму**. Там це проявилось у тому, що випадковий ліс не дав переваги над одним деревом (різниця −0.0009), а керований експеримент показав, що перевага ансамблю з'являється лише зі штучно доданим шумом.

Той самий факт пояснює і результат тут: якщо шуму немає, найближчий сусід і є правильною відповіддю, а усереднення по $k > 1$ лише втягує в рішення чужі приклади. **Дві різні роботи незалежно виміряли одну й ту саму властивість даних.**

3.4 Особливість № 3: прокляття розмірності

Головна слабкість kNN. У просторі високої розмірності відстані **концентруються**: різниця між найближчим і найдальшим сусідом стає відносно малою, і поняття близькості втрачає сенс.

Перевірено прямо: до даних додавались випадкові ознаки без жодної інформації.

Шумових ознак	Всього ознак	kNN	Випадковий ліс	Втрата kNN	min/max відстані
0	13	0.9492	0.9828	—	0.0001
10	23	0.8258	0.9682	−0.1234	0.0812
50	63	0.6102	0.9567	−0.3390	0.2969
200	213	**0.4659**	0.9343	**−0.4833**	**0.5447**

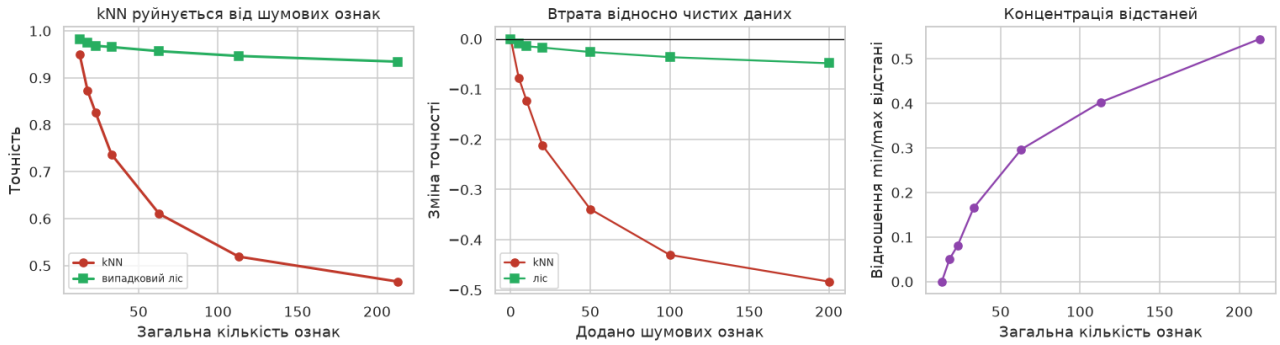


Рисунок 3: Прокляття розмірності

Двісті нерелевантних ознак відбирають у kNN **48 пунктів** точності — метод падає майже до рівня випадкового вгадування. Випадковий ліс на тих самих даних втрачає лише **4.9 пункта**, бо здатен нерелевантні ознаки просто не обирати для розбиття.

Третій стовпець вимірює механізм безпосередньо: відношення мінімальної відстані між точками до максимальної зростає з 0.0001 до 0.5447. Тобто найближчий і найдальший сусіди стають майже рівновіддаленими, і «найближчий» перестає щось означати.

3.5 Особливість № 4: щільність вибірки та вартість передбачення

Розмір вибірки	Точність	Навчання, мс	Передбачення, мс
1 000	0.908	1.6	5.7
10 000	0.949	15.2	48.8
40 000	0.977	76.0	268.4
80 000	**0.981**	145.5	493.2

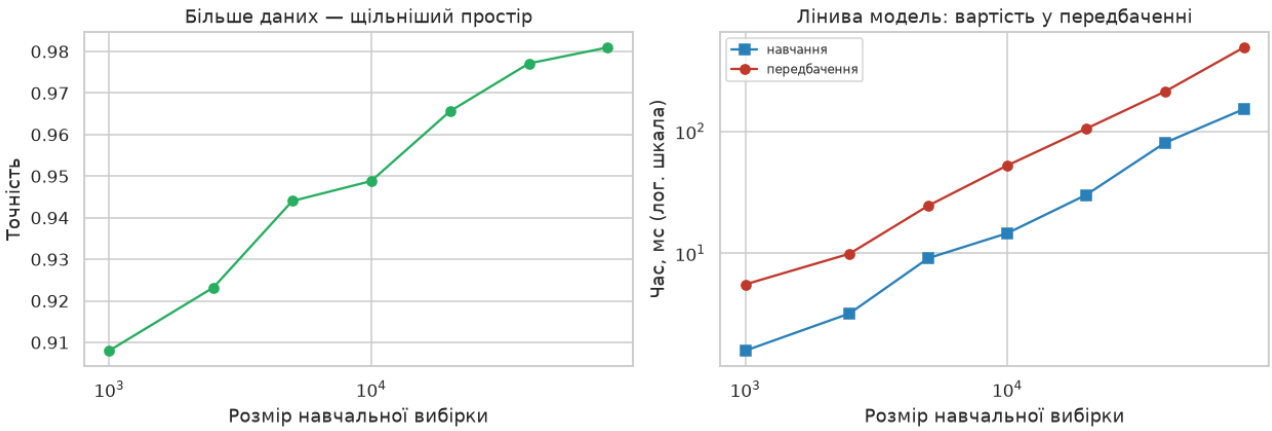


Рисунок 4: Лінива модель

Точність зростає з розміром вибірки монотонно й не виходить на плато: більше даних означає щільніший простір і ближчих сусідів. На повних 80 000 прикладів kNN дає 0.981 — помітно більше, ніж 0.9703 на основній підвибірці.

Водночас передбачення коштує дорожче за навчання (493 мс проти 145 мс на 80 000). Варто зазначити, що на практиці «навчання» kNN у `scikit-learn` не є безкоштовним: бібліотека будує просторовий індекс, тож час навчання теж зростає з розміром даних. Класичне уявлення про нульову вартість навчання справедливе лише для реалізації повним перебором.

Окремий замір трьох структур пошуку на цих даних:

Структура	Навчання, с	Передбачення, с	Точність
`brute`	0.041	0.205	0.9731
`kd_tree`	0.052	**0.145**	0.9727
`ball_tree`	0.040	1.298	0.9727

За 13 вимірів **KD-дерево виявилось найшвидшим** — на 30 % швидшим за повний перебір, — тоді як ball-дерево програє обом у 6–9 разів. Тобто просторовий індекс тут окупається, але лише правильно дібраний: ball-дерево розраховане на високу розмірність і на такій задачі лише додає накладних витрат. Точність усіх трьох збігається з точністю до похибки розв’язання нічиїх.

4 Результати

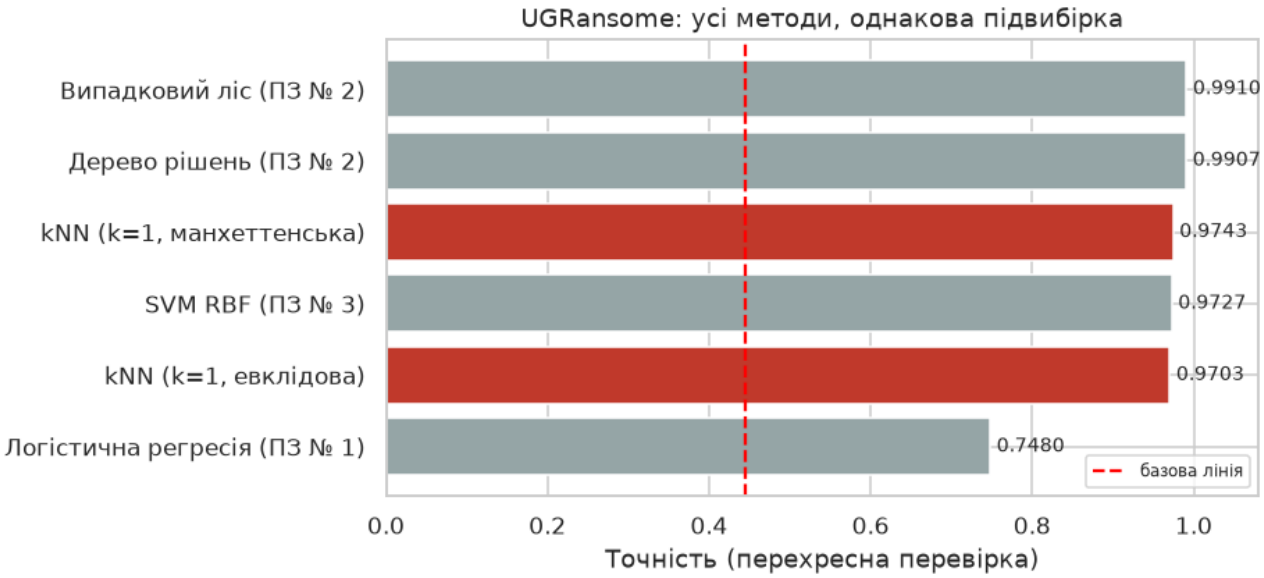


Рисунок 5: Порівняння методів

Модель	Точність (CV)	F1-macro
Випадковий ліс (ПЗ № 2)	0.9910	0.9914
Дерево рішень (ПЗ № 2)	0.9907	0.9905
SVM RBF (ПЗ № 3)	0.9727	0.9715
kNN (k = 1, манхеттенська)	**0.9743**	0.9757
kNN (k = 1, евклідова)	0.9703	0.9722
Логістична регресія	0.7480	0.7263

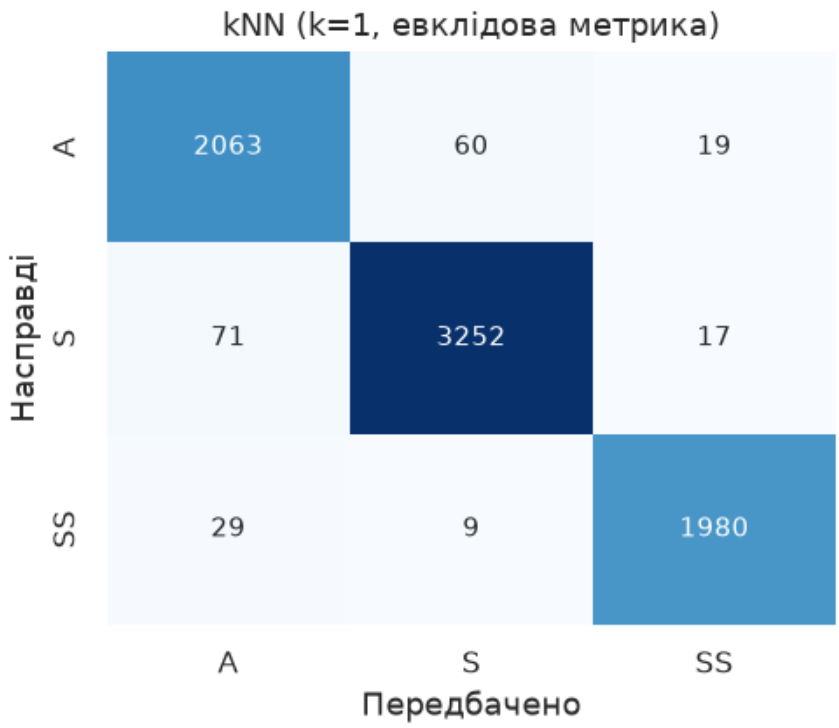


Рисунок 6: Матриця невідповідностей

Усі моделі в таблиці оцінено однаково — на тій самій підвибірці 30 000 записів із **триблоковою** перехресною перевіркою. Через це показники дерева й лісу нижчі за наведені в практичному занятті № 2 (0.9943 і 0.9934), де використано повний датасет і п’ять блоків; у межах цієї таблиці порівняння коректне.

5 Аналіз

5.1 Переваги методу

- **Немає припущень про форму межі.** kNN не вимагає, щоб класи розділялись гіперплощиною чи гладкою поверхнею; межа може бути якою завгодно складною.
- **Тривіальне донавчання.** Додати нові приклади означає просто дописати їх до вибірки — перенавчати нічого не треба. Для системи виявлення інцидентів, куди постійно надходять нові розмічені випадки, це практична перевага.
- **Один зрозумілий параметр.** На відміну від SVM з його `C` і `gamma`, тут налаштовується здебільшого k.
- **Природна багатокласовість** — голосування працює для будь-якої кількості класів без змін.

5.2 Недоліки методу

- **Прокляття розмірності** — критичний недолік: 200 нерелевантних ознак коштують 48 пунктів точності проти 4.9 у випадкового лісу.

- **Вартість передбачення зростає з обсягом даних**, тобто модель стає дедалі повільнішою саме тоді, коли вона стає точнішою.
- **Потрібно зберігати всю навчальну вибірку** — для 149 043 записів це вся таблиця в пам'яті, тоді як дерево займає 1 465 вузлів.
- **Чутливість до масштабу**, причому, як показано вище, у неочевидний бік.
- **Немає інтерпретованої моделі**: пояснення зводиться до «схожі приклади належали до цього класу», без правил, які можна прочитати.

5.3 Порівняння з іншими методами

kNN з евклідовою метрикою (0.9703) практично зрівнявся з SVM (0.9727), а з манхеттенською (0.9743) навіть трохи випередив його; деревам (0.991) поступились обидва варіанти. Причина та сама, що й у SVM: обидва методи спираються на відстані у неперервному просторі, а UGRansome складається переважно з категоріальних ознак, закодованих цілими числами. Таке кодування нав'язує категоріям неіснуючий порядок — «відстань» між `Flag=2` і `Flag=5` не має змісту, тоді як дерево просто розділяє категорії розбиттями.

6 Висновки

1. Метод kNN реалізовано на датасеті UGRansome; найкраща конфігурація ($k = 1$, манхеттенська метрика, стандартизація) дала точність **0.9743** за базової лінії 0.4454; з евклідовою метрикою — 0.9703 за F1-macro 0.9722.

2. Масштабування може шкодити. Всупереч загальному правилу, тут `StandardScaler` знижує точність (до −0.0144 за $k = 15$), бо найширша за розмахом ознака `USD` є водночас найінформативнішою, і нерівні масштаби випадково дають правильне зважування. Масштабування корисне тоді, коли розмах ознаки не корелює з її інформативністю.

3. **Оптимальне $k = 1$ підтверджує висновок практичного заняття № 2** про відсутність шуму в UGRansome: якщо шуму немає, найближчий сусід і є відповіддю. Дві незалежні роботи виміряли одну властивість даних різними способами.

4. Прокляття розмірності підтверджено кількісно: 200 шумових ознак відбирають у kNN 48 пунктів точності проти 4.9 у випадкового лісу, а відношення min/max відстані зростає з 0.0001 до 0.5447, тобто поняття близькості вироджується.

5. Точність kNN зростає з обсягом даних монотонно (0.908 при 1 000 записів → 0.981 при 80 000) і не виходить на плато, але разом з нею зростає вартість передбачення.

6. На цьому датасеті kNN поступається деревам (0.9743 проти 0.9910) з тієї ж причини, що й SVM: методи, засновані на відстанях, погано працюють з категоріальними ознаками, закодованими цілими числами. kNN, однак, випереджає SVM — 0.9743 проти 0.9727.

7. Вибір структури пошуку не зводиться до «дерева проти перебору»: на 13 вимірах KD-дерево виявилось найшвидшим (0.145 с проти 0.205 с у повного перебору), тоді як ball-дерево програло обом у 6–9 разів. Індекс окупається, але лише дібраний під розмірність задачі.

7 Джерела

1. UGRansome dataset. URL: https://www.kaggle.com/datasets/nkongolo/ugransome-dataset
2. Cover T., Hart P. Nearest neighbor pattern classification // IEEE Transactions on Information Theory. 1967. Vol. 13. P. 21–27.
3. Beyer K. et al. When Is “Nearest Neighbor” Meaningful? // ICDT. 1999. P. 217–235.
4. Scikit-learn: Nearest Neighbors. URL: https://scikit-learn.org/stable/modules/neighbors.html