МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

ЗВІТ

з дисципліни «Аналіз кіберінцидентів»

Практичне заняття № 6 — Метод k-середніх та ієрархічна кластеризація

Виконав: Вовкотруб Олександр Віталійович
Група: ФБ-61мн

Перевірив: Наконечна Юлія Володимирівна

Київ — 2026

Зміст

1 Мета роботи **2**

2 Постановка задачі **2**

2.1 Дві родини метрик 2

3 Хід виконання **2**

3.1 Вибір кількості кластерів у методі k-середніх 2

3.2 Відповідність кластерів справжнім класам 3

3.3 Ієрархічна кластеризація 4

3.3.1 Силует обирає вироджене розбиття 5

3.4 Залежність від параметрів даних 5

3.4.1 Масштабування 5

3.4.2 Розмірність простору 6

4 Результати **6**

5 Аналіз **7**

5.1 Кластеризація не відновлює класи — і це не помилка методу 7

5.2 Переваги та недоліки методів 7

6 Висновки **7**

7 Джерела **8**

1 Мета роботи

Реалізувати алгоритми k-середніх та ієрархічної кластеризації, дослідити залежність якості кластеризації від параметрів даних і з'ясувати, наскільки структура, знайдена без учителя, відповідає відомій розмітці.

2 Постановка задачі

Використано датасет **UGRansome** — той самий, що в практичних заняттях № 2, № 3 і № 5, на стратифікованій підвибірці **20 000 записів** для k-середніх. Це дає рідкісну можливість: ми **знаємо** справжні мітки (`S/A/SS`) і знаємо, що методи з учителем досягають на них 99.4 % точності. Отже, можна поставити питання, на яке в реальній задачі кластеризації відповісти неможливо — **чи знаходить кластеризація саме ту структуру, яку шукає класифікація?**

2.1 Дві родини метрик

Це перша задача навчання **без учителя**, тому змінюється поняття «точності»:

- **Внутрішні метрики** (інерція, силует) оцінюють кластери самі по собі — наскільки вони щільні й відокремлені. Міток не потребують, тому доступні завжди.
- **Зовнішні метрики** (ARI, NMI, однорідність, повнота) порівнюють знайдені кластери з відомими класами. У реальній задачі недоступні.

ARI дорівнює 0 для випадкового розбиття і 1 для повного збігу.

3 Хід виконання

3.1 Вибір кількості кластерів у методі k-середніх

k	Інерція	Силует	ARI	NMI	Однорідність	Повнота
2	232 614	0.1337	0.0867	0.1531	0.1200	0.2112
3	215 581	0.1054	0.2010	0.2159	0.2176	0.2141
4	198 235	0.1167	**0.2480**	0.2614	0.2926	0.2361
8	147 457	0.1732	0.1043	0.1842	0.2498	0.1459
10	133 995	**0.1746**	0.1216	0.2231	0.3345	0.1674

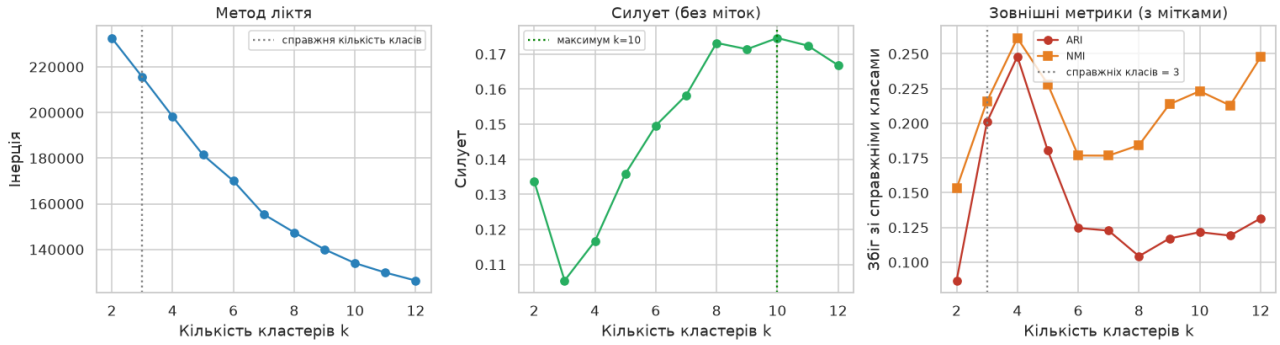


Рисунок 1: Вибір кількості кластерів

Внутрішня та зовнішня метрики вказують на різне. Силует максимальний за $k = 10$, ARI — за $k = 4$, а справжніх класів **три**. У реальній задачі доступний лише силует, тож, керуючись ним, дослідник обрав би десять кластерів — утричі більше за дійсну кількість класів.

Метод ліктя теж не рятує: інерція спадає плавно, без вираженого зламу.

3.2 Відповідність кластерів справжнім класам

Таблиця відповідності для $k = 3$:

Справжній клас	Кластер 0	Кластер 1	Кластер 2
A	433	1 945	3 333
S	4 714	3 535	659
SS	328	1 306	3 747

Метрика	Значення
ARI	0.2010
NMI	0.2159
Однорідність	0.2176
Повнота	0.2141

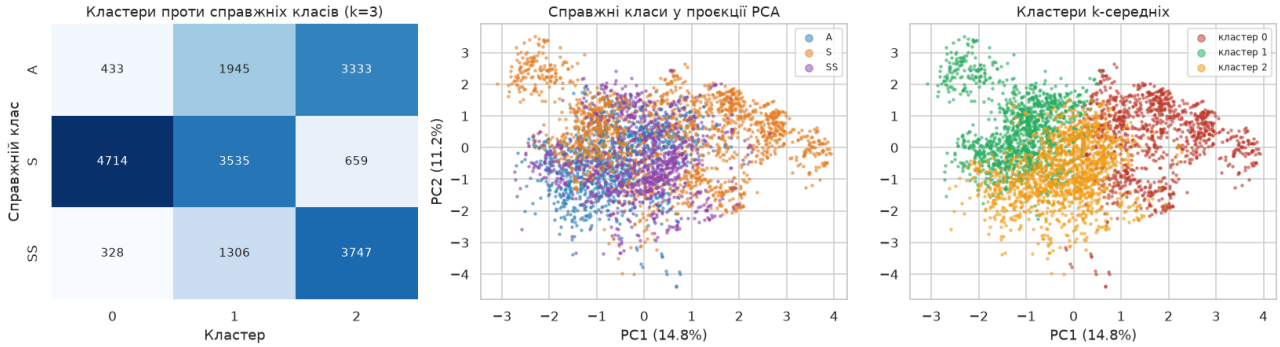


Рисунок 2: Кластери проти класів

Жоден кластер не відповідає жодному класу. Клас `S` переважає в кластері 0, але навіть там становить лише 86 % — і водночас 3 535 його записів опинились у кластері 1. Однорідність 0.22 означає, що кластери здебільшого змішані.

0.9943 точності з учителем проти ARI 0.2010 без нього — на тих самих даних, з тими самими ознаками.

Проєкція PCA пояснює лише 26 % дисперсії, тобто структура даних істотно багатовимірна й у двох вимірах не візуалізується.

3.3 Ієрархічна кластеризація

Агломеративний підхід: кожна точка спочатку є окремим кластером, найближчі пари послідовно об’єднуються. Складність за пам’яттю $O(n^2)$, тому підвибірка 5 000 записів.

Зв’язування	ARI	NMI	Силует	Найбільший кластер
ward	**0.1270**	0.1864	0.1363	**57.5 %**
complete	0.0018	0.0106	0.3998	99.5 %
average	0.0018	0.0106	**0.4803**	**99.5 %**
single	0.0005	0.0023	0.3444	**99.9 %**

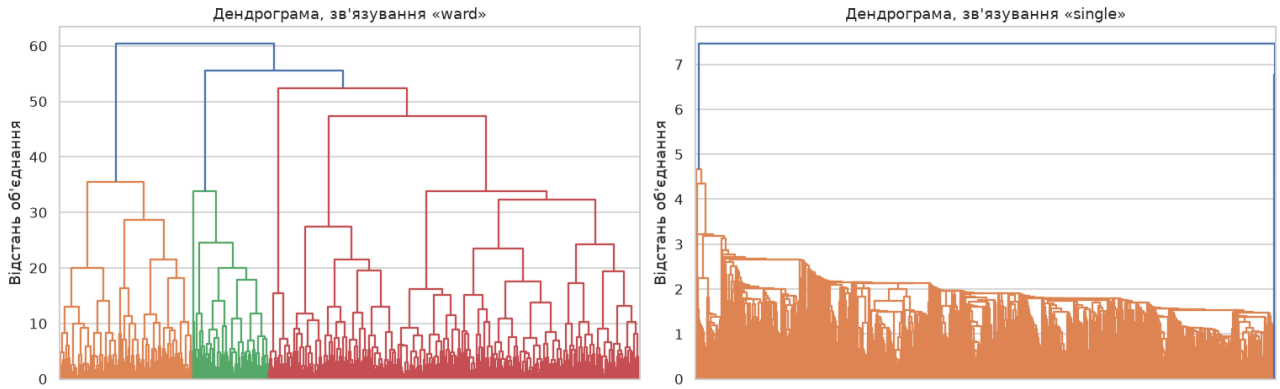


Рисунок 3: Дендрограми

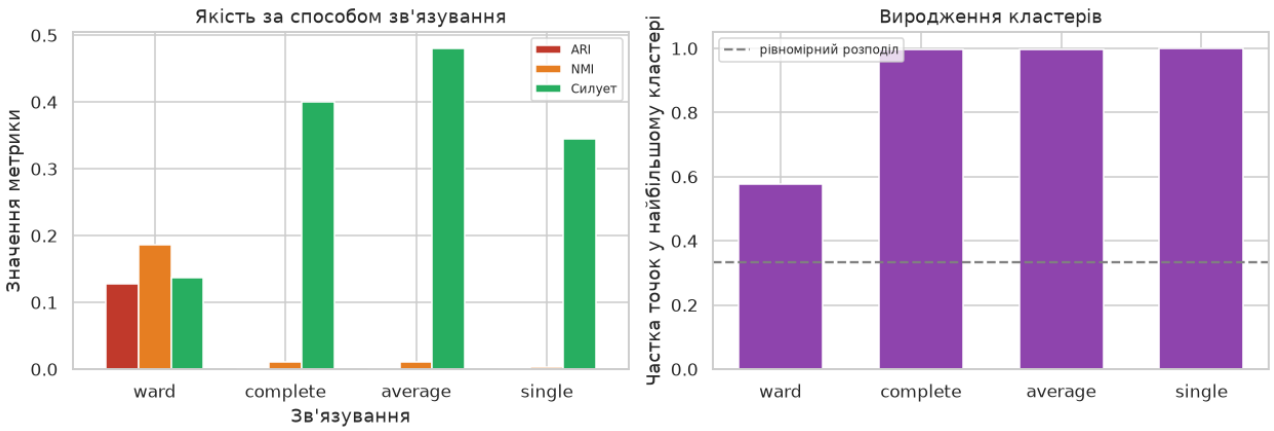


Рисунок 4: Порівняння способів зв’язування

3.3.1 Силует обирає вироджене розбиття

Зв’язування `average` дає **найкращий силует (0.4803)** — утричі кращий за `ward`. І при цьому воно поміщає **99.5 % усіх точок в один кластер**, а ARI становить 0.0018, тобто розбиття практично випадкове.

Пояснення просте: силует винагороджує щільні відокремлені кластери. Розбиття «одна велика маса плюс кілька віддалених викидів» формально ідеальне — маса щільна, викиди далеко, — але змістовно безглузде. На ланцюговий ефект страждає власне `single`, який послідовно приєднує точки до однієї великої групи; `complete` і `average` вироджуються з іншої причини — через кілька екстремальних викидів за `USD`, які вони відсаджують в окремі мікрокластери, лишаючи решту однією масою.

Внутрішня метрика не просто не допомагає — вона активно вводить в оману. Якби вибір способу зв’язування робився за силуетом, було б обрано найгірше з чотирьох рішень. Єдиний надійний захист — дивитись на розміри кластерів: частка 99.5 % у найбільшому одразу видає виродження.

Придатним виявився лише `ward`, який мінімізує приріст внутрішньокластерної дисперсії й тому опирається злипанню.

3.4 Залежність від параметрів даних

3.4.1 Масштабування

Підготовка	ARI	Силует	Найбільший кластер
Без масштабування	**0.3155**	**0.7545**	58.2 %
StandardScaler	0.2010	0.1054	38.7 %

Масштабування знову **погіршує** зовнішню метрику — так само, як у практичному занятті № 5 для kNN. Причина та сама і вже встановлена там: ознака `USD` є водночас найінформативнішою (важливість 0.2407) і найширшою за розмахом (126 378). Без

масштабування відстані визначаються переважно нею, тобто дані випадково отримують корисне зважування.

Проте висновок не однозначний: без масштабування найбільший кластер містить 58 % точок проти 39 % зі стандартизацією, тобто розбиття помітно менш збалансоване. Висока внутрішня метрика (силует 0.7545) знову досягається частково за рахунок виродження.

3.4.2 Розмірність простору

Шумових ознак	Всього ознак	ARI	Силует
0	13	0.1148	0.1376
10	23	0.1166	0.0729
50	63	0.1149	0.0251
100	113	0.1132	**0.0136**

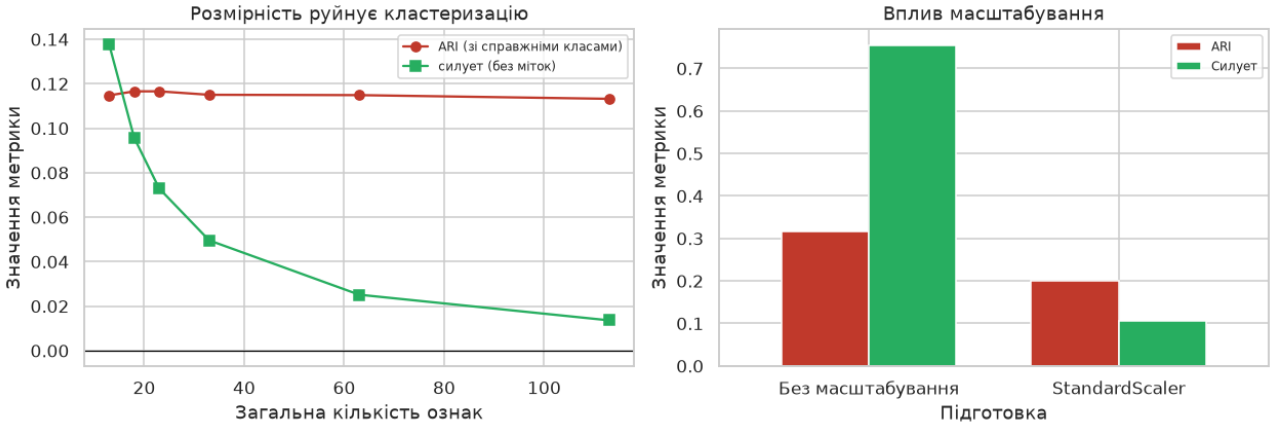


Рисунок 5: Вплив параметрів даних

Тут поведінка відрізняється від kNN (практичне заняття № 5), де 200 шумових ознак відібрали 48 пунктів точності. Кластеризація натомість майже не змінюється за ARI (0.1148 → 0.1132), зате **силует падає вдесятеро** (0.1376 → 0.0136).

Пояснення: ARI вже був низьким, і псувати не було чого — кластеризація й на чистих даних не відповідала класам. Силует же чесно фіксує, що зі зростанням розмірності точки стають рівновіддаленими й структура зникає. Тобто в цьому експерименті внутрішня метрика виявилась чутливішою за зовнішню.

4 Результати

Метод	ARI	Примітка
k-середніх (k = 3)	0.2010	справжня кількість класів
k-середніх (k = 4)	**0.2480**	найкраще досягнуте
Ієрархічна (`ward`, k = 3)	0.1270	підвибірка 5 000
Ієрархічна (`average`)	0.0018	вироджене розбиття
Для довідки: класифікація (ПЗ № 2)	*точність 0.9943*	*з учителем*

5 Аналіз

5.1 Кластеризація не відновлює класи — і це не помилка методу

Найкращий досягнутий ARI становить 0.2480, тоді як класифікація на тих самих ознаках дає 0.9943. Розрив принциповий і має змістовне пояснення.

Мітки `S/A/SS` — це **рішення аналітика** про спосіб виявлення загрози (сигнатурний, аномальний, синтетично-сигнатурний), а не природні скупчення точок у просторі ознак. Класифікатор має вчителя, який показує саме цей поділ, і тому знаходить розділювальні правила навіть тоді, коли класи геометрично перемішані. Кластеризація ж шукає щільні групи — а вони в цих даних утворюються за іншими ознаками (переважно за обсягами транзакцій `USD` і `BTC`).

Практичний висновок для аналізу кіберінцидентів: кластеризацію не слід розглядати як заміну класифікації за відсутності міток. Вона відповідає на інше питання — «які групи схожої активності є в трафіку?», а не «до якого з відомих типів належить ця подія?». Її природна ніша — розвідувальний аналіз і пошук раніше невідомих патернів.

5.2 Переваги та недоліки методів

k-середніх. Швидкий, лінійний за кількістю точок, легко масштабується. Але вимагає задати k наперед, шукає лише опуклі кластери приблизно однакового розміру й чутливий до початкової ініціалізації.

Ієрархічна кластеризація. Не вимагає задавати кількість кластерів наперед — дендрограму можна зрізати на будь-якій висоті; дає наочну структуру вкладеності. Але має складність $O(n^2)$ за пам'яттю, через що 149 043 записи довелось звести до 5 000, і вкрай чутлива до способу зв'язування: три з чотирьох випробуваних дали вироджені розбиття.

6 Висновки

1. Обидва алгоритми реалізовано на датасеті UGRansome. Найкращий результат k-середніх — ARI = 0.2480 за $k = 4$; ієрархічної кластеризації зі зв'язуванням `ward` — ARI = 0.1270.

2. Кластеризація не відновлює справжні класи: ARI 0.2480 проти точності 0.9943 у класифікації на тих самих даних. Мітки `S/A/SS` відображають спосіб виявлення загрози, а не геометричні скупчення в просторі ознак.
3. Внутрішні метрики можуть вводити в оману. Зв'язування `average` дає найкращий силует (0.4803) і водночас поміщає 99.5 % точок в один кластер за ARI 0.0018. Надійніший захист від такого виродження — контроль розмірів кластерів, а не оптимізація силуету.
4. Внутрішня та зовнішня метрики не узгоджуються у виборі k: силует радить $k = 10$, ARI — $k = 4$, справжніх класів три. У реальній задачі доступний лише силует, тому помилка була б неминучою.
5. Масштабування погіршує ARI (0.3155 → 0.2010) — той самий ефект, що встановлено для kNN у практичному занятті № 5, і з тієї ж причини: розмах ознаки `USD` збігається з її інформативністю.
6. Розмірність руйнує внутрішню структуру, але майже не змінює ARI: 100 шумових ознак знижують силует удесятеро (0.1376 → 0.0136) за практично сталого ARI, бо відповідність класам була низькою від початку.

7 Джерела

1. UGRansome dataset. URL: https://www.kaggle.com/datasets/nkongolo/ugransome-dataset
2. Rousseeuw P. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis // Journal of Computational and Applied Mathematics. 1987. Vol. 20. P. 53–65.
3. Hubert L., Arabie P. Comparing partitions // Journal of Classification. 1985. Vol. 2. P. 193–218.
4. Scikit-learn: Clustering. URL: https://scikit-learn.org/stable/modules/clustering.html