МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

ЗВІТ

з дисципліни «Аналіз кіберінцидентів»

Практичне заняття № 8 — Метод DBSCAN і A/B-тестування

Виконав: Вовкотруб Олександр Віталійович
Група: ФБ-61мн

Перевірив: Наконечна Юлія Володимирівна

Київ — 2026

Зміст

1 Мета роботи **2**

2 Постановка задачі **2**

3 Частина 1. DBSCAN **2**

3.1 Ідея методу 2

3.2 Вибір параметра eps 2

3.3 Поведінка на UGRansome 3

3.4 Де DBSCAN справді сильніший 4

3.5 DBSCAN як детектор аномалій 5

4 Частина 2. A/B-тестування **6**

4.1 Постановка 6

4.2 Z-тест для двох часток 6

4.3 Критерій Мак-Немара 6

4.4 Потужність і потрібний обсяг вибірки 7

4.5 Проблема «підглядання» 7

5 Результати **8**

6 Висновки **9**

7 Джерела **9**

1 Мета роботи

Дослідити роботу алгоритму кластеризації на основі щільності DBSCAN та методику A/B-тестування для статистичної перевірки різниці між двома варіантами системи.

2 Постановка задачі

Робота складається з двох незалежних частин. **DBSCAN** — алгоритм кластеризації; **A/B-тестування** — статистична перевірка гіпотез. Спільним є питання, на яке обидва відповідають: чи є спостережувана структура (різниця) реальною, чи це випадковість.

Використано датасет **UGRansome** — той самий, що в практичних заняттях № 2, № 3, № 5 і № 6, на стратифікованій підвибірці **15 000 записів**. У занятті № 6 на ньому вже досліджено k-середніх та ієрархічну кластеризацію, тож DBSCAN порівнюється безпосередньо.

---

3 Частина 1. DBSCAN

3.1 Ідея методу

DBSCAN визначає кластери як **області високої щільності**, розділені областями низької. Кожна точка отримує одну з трьох ролей: **ядрова** (у ε-околі не менше `min_samples` точок), **межова** (потрапляє в окіл ядрової) або **шум** (не належить жодному кластеру).

Три властивості відрізняють його від k-середніх: не потрібно задавати кількість кластерів наперед, кластери можуть мати **довільну форму**, і викиди позначаються **явно**.

3.2 Вибір параметра eps

Стандартний спосіб — графік k-відстаней: для кожної точки береться відстань до k-го сусіда, значення сортуються, і шукається «коліно».

Перцентиль	Відстань до 10-го сусіда
50 %	0.85
90 %	1.56
95 %	1.83
99 %	2.34

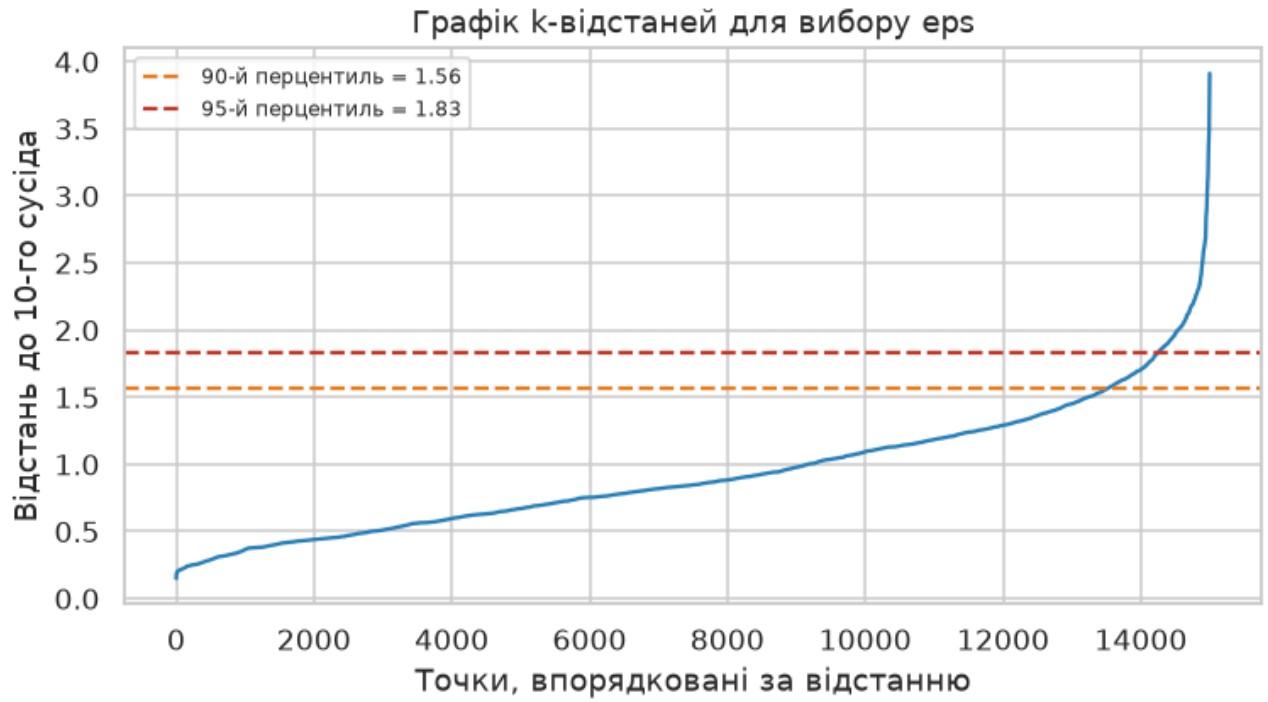


Рисунок 1: Графік k-відстаней

3.3 Поведінка на UGRansome

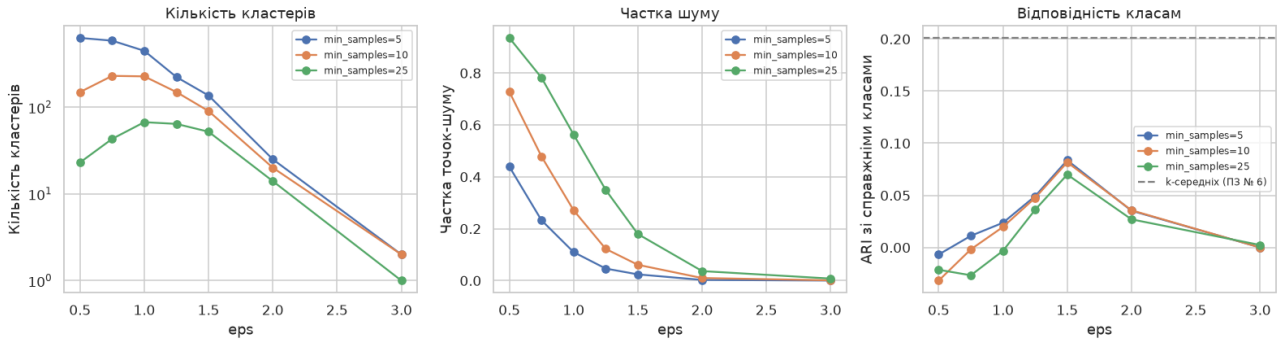


Рисунок 2: Сітка параметрів DBSCAN

eps	min_samples	Кластерів	Шуму	ARI
0.5	10	149	72.7 %	−0.0318
1.0	10	226	27.1 %	0.0197
1.5	**5**	136	2.4 %	**0.0837**
1.5	10	90	6.1 %	0.0817
2.0	10	20	1.0 %	0.0357
3.0	10	2	0.1 %	−0.0000

DBSCAN на цих даних програє k-середнім: найкращий ARI становить 0.0837 проти 0.2010 у практичному занятті № 6. Причина видна з таблиці: проміжного режиму немає. За

малих `eps` алгоритм дробить дані на сотні дрібних кластерів і оголошує шумом до 73 % точок; за великих — злипає все у два кластери. Це прямо підтверджує висновок заняття № 6 про **відсутність у датасеті вираженої щільнісної структури**.

3.4 Де DBSCAN справді сильніший

Щоб показати, де метод дійсно виграє, обидва алгоритми застосовано до синтетичних наборів з неопуклими кластерами:

Набір	k-середніх (ARI)	DBSCAN (ARI)
Місяці	0.4841	**1.0000**
Концентричні кола	**−0.0006**	**1.0000**
Кулясті скупчення	1.0000	1.0000

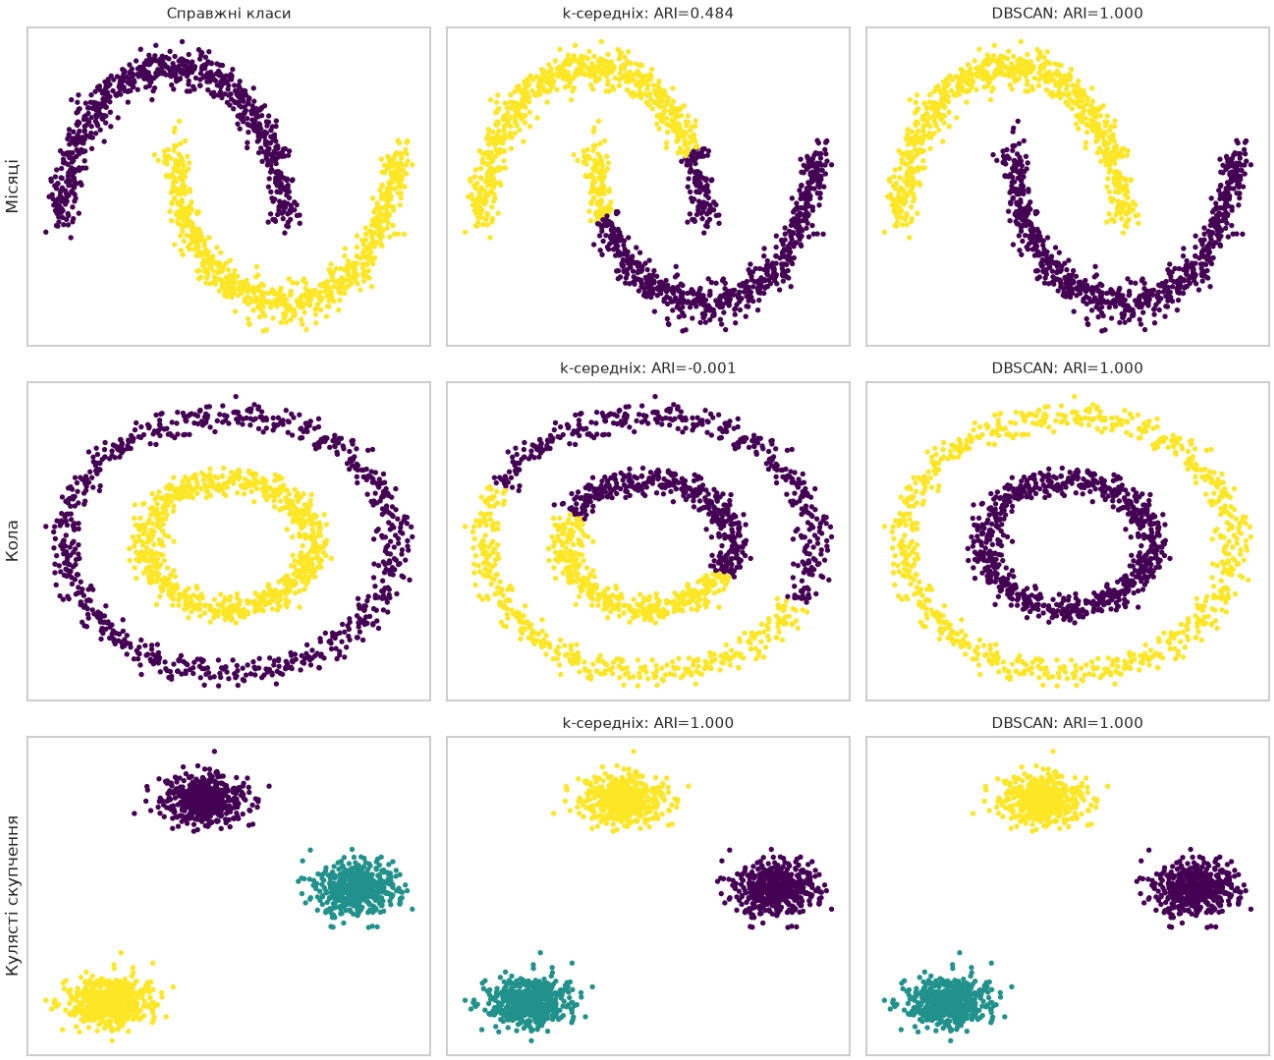


Рисунок 3: DBSCAN проти k-середніх на синтетичних даних

На концентричних колах k-середніх дає ARI **−0.0006**, тобто працює гірше за випадкове розбиття: метод шукає кулясті скупчення й неминуче розрізає кільця навпіл замість

відокремити внутрішнє від зовнішнього. DBSCAN обидва набори розв'язує **ідеально**, а на кулястих скупченнях не поступається k-середнім.

Отже, слабкість DBSCAN на UGRansome — властивість даних, а не алгоритму.

3.5 DBSCAN як детектор аномалій

Найпрактичніше застосування DBSCAN для аналізу кіберінцидентів — не кластеризація як така, а позначення точок-шуму. Перевірено, чи відповідають вони класу A (Anomaly). Базова частка класу A у вибірці — 0.2855.

eps	Частка шуму	Класу A серед шуму	Lift
0.75	47.8 %	0.3936	1.38×
1.00	27.1 %	**0.4063**	**1.42×**
1.50	6.1 %	0.3688	1.29×
2.00	1.0 %	0.3082	1.08×

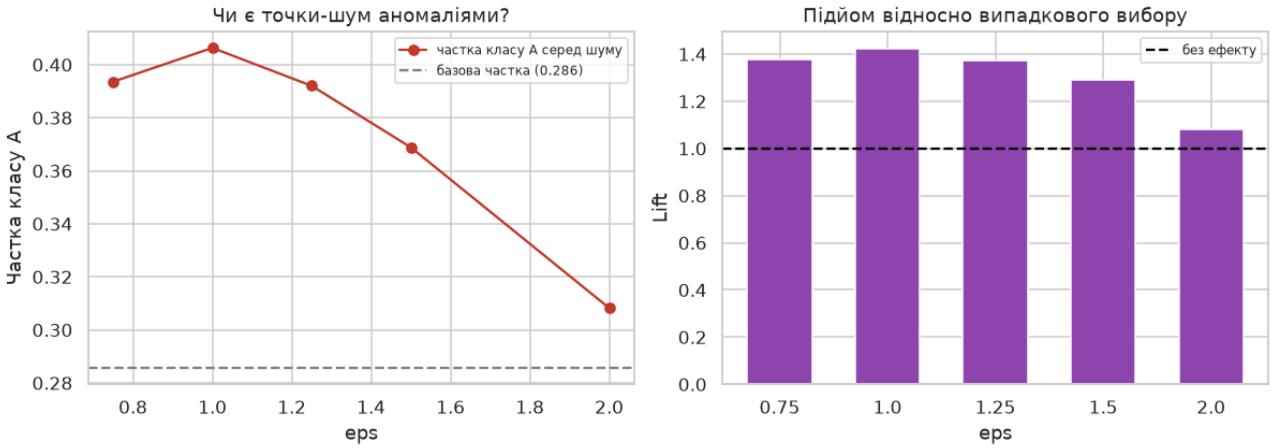


Рисунок 4: Шум як детектор аномалій

Зв'язок існує, але слабкий: серед точок-шуму частка аномалій у 1.42 раза вища за базову. Це означає, що щільнісні викиди **корелюють** із розміченими аномаліями, проте як самостійний детектор непридатні — 59 % позначених точок аномаліями не є. Причина в тому, що мітка A описує спосіб виявлення загрози аналітиком, а не геометричну ізольованість точки. Це той самий висновок, що й у практичному занятті № 6.

Показово також, що lift **не зростає зі звуженням критерію викиду**: він сягає максимуму за eps = 1.0 (1.42×), а далі спадає до 1.08× за eps = 2.0. Тобто чим суворіше ми відбираємо «найвикидовіші» точки, тим **меншою** стає частка аномалій серед них. Це протилежне очікуваному й зайвий раз свідчить, що щільнісна ізольованість тут не є ознакою аномальності.

4 Частина 2. A/B-тестування

4.1 Постановка

Практична задача: у системі виявлення інцидентів пропонується замінити наявну модель (**варіант A** — дерево рішень глибини 5) на нову (**варіант B** — випадковий ліс). Питання: чи справді B краща, чи різниця випадкова?

- H_0**:** частки правильних рішень однакові, $p_A = p_B$;
- H_1**:** $p_A \neq p_B$.

Тестова вибірка: $n = 4\,500$.

Варіант	Правильних	Частка
A (дерево, depth = 5)	4 121	0.9158
B (ліс, 50 дерев)	4 449	**0.9887**
Різниця		**+0.0729**

4.2 Z-тест для двох часток

Класичний двовибірковий z-тест дає $z = 16.21$ і $p < 10^{-15}$; 95 % довірчий інтервал різниці не містить нуля. Нульова гіпотеза відхиляється: різниця статистично значуща.

4.3 Критерій Мак-Немара

Z-тест припускає **незалежні вибірки**, але тут обидві моделі оцінюються на **тих самих** прикладах — вибірки парні. Коректніший критерій Мак-Немара враховує лише розбіжні пари:

	A правильна	A помилилась
B правильна	4 102	**347**
B помилилась	**19**	32

$$\chi^2 = \frac{(|347 - 19| - 1)^2}{347 + 19} = 292.16, \quad p < 10^{-15}$$

Розбіжних пар лише 366 з 4 500 (8.1 %). Критерій використовує саме ці 366 пар замість усіх 4 500 — і саме тому він **чутливіший**: решта спостережень, де обидві моделі поводяться однаково, не несуть інформації про різницю між ними.

У 347 випадках B виправляє помилку A і лише у 19 — навпаки: перевага B майже одностороння.

4.4 Потужність і потрібний обсяг вибірки

p-значення відповідає, **чи є** ефект. Перед експериментом важливіше знати, **скільки спостережень потрібно**, щоб ефект заданого розміру взагалі можна було виявити.

Мінімальний ефект (MDE)	Потрібно на групу
0.1 %	1 204 219
0.5 %	47 120
1 %	11 450
2 %	2 696
5 %	349

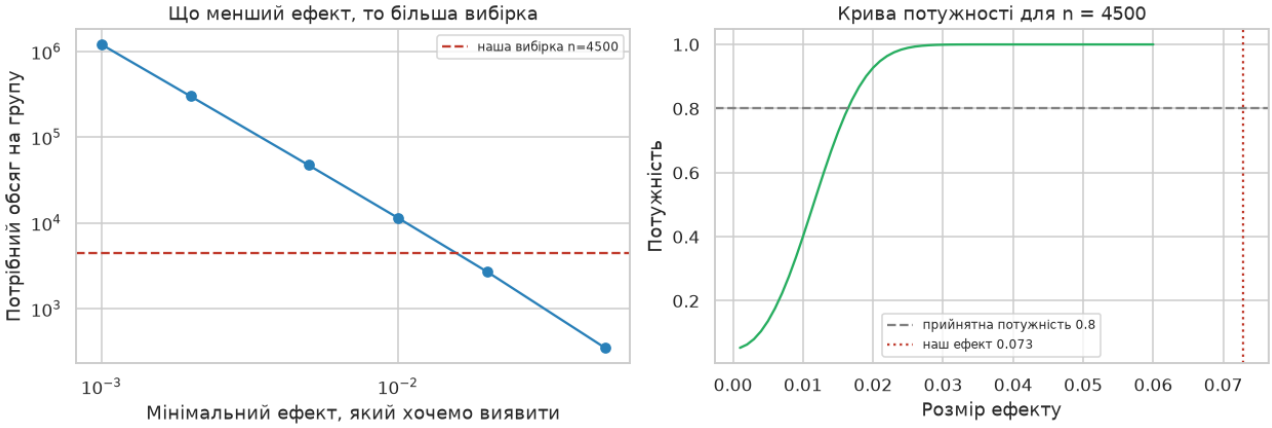


Рисунок 5: Потужність

Залежність квадратична: щоб виявити ефект удвічі менший, потрібно вчетверо більше даних. Наш ефект (+7.3 %) виявляється надійно навіть на кількох сотнях спостережень, але виявити різницю у 0.1 % на тій самій вибірці було б неможливо — знадобилося б понад мільйон спостережень на групу.

4.5 Проблема «підглядання»

Типова помилка на практиці: дивитись на p-значення в міру накопичення даних і зупиняти експеримент, щойно воно опуститься нижче 0.05. Змодельовано ситуацію, коли **обидва варіанти насправді однакові** (H_0 істинна):

Кількість перевірок	Частка хибнопозитивних
1 (лише в кінці)	**5.3 %**
20 (упродовж)	**24.5 %**

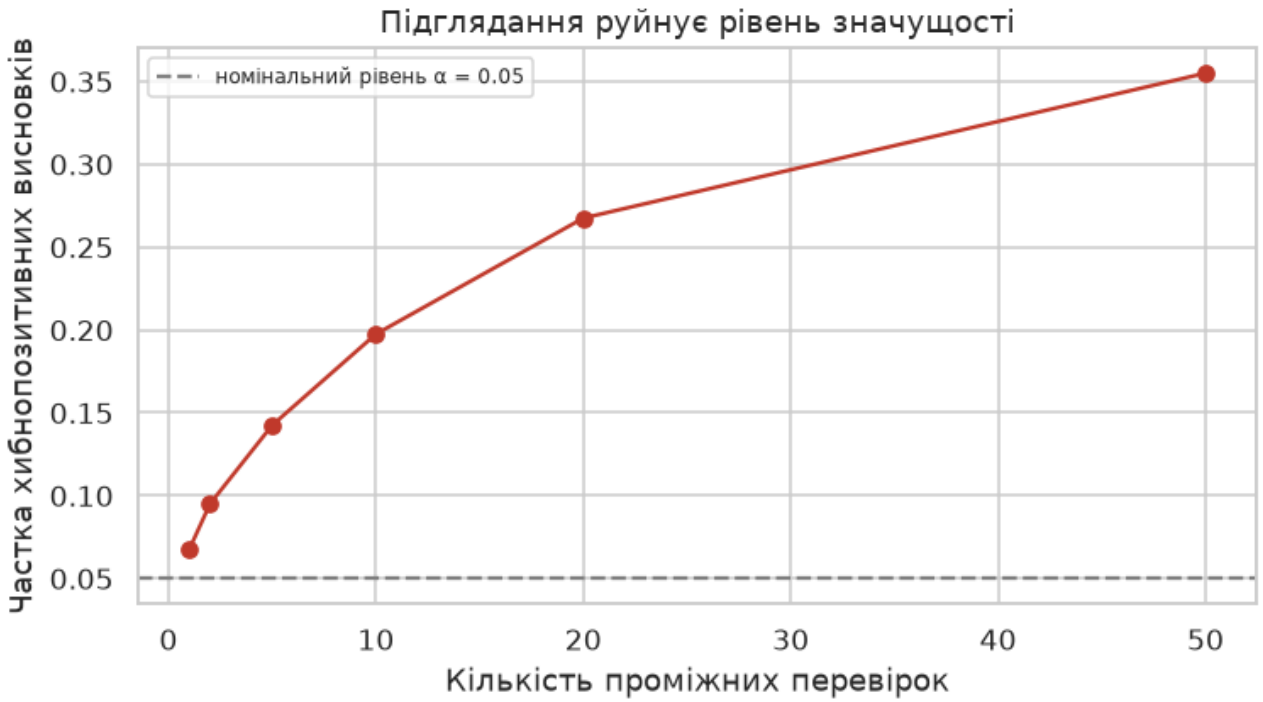


Рисунок 6: Ефект підглядання

За одноразової перевірки частка хибних відкриттів становить 5.3 %, тобто відповідає заявленому рівню $\alpha = 0.05$. За двадцяти проміжних перевірок вона зростає до **24.5 %** — у 4.6 раза. Кожне «підглядання» дає новий шанс випадково перетнути поріг, і рівень значущості перестає означати те, що заявлено.

Практичний висновок: обсяг вибірки треба фіксувати **до** початку експерименту, а для проміжного контролю застосовувати спеціальні методи послідовного аналізу з поправкою на кількість перевірок.

5 Результати

Показник	Значення
DBSCAN, найкращий ARI на UGRansome	0.0837
k-середніх, ARI (ПЗ № 6)	0.2010
DBSCAN на концентричних колах	**1.0000** (k-середніх: −0.0006)
DBSCAN, lift шуму щодо класу A	1.42×
A/B: точність A / B	0.9158 / 0.9887
A/B: p-значення (Мак-Немар)	$< 10^{-15}$
Хибнопозитивних за 20 підглядань	24.5 %

6 Висновки

1. DBSCAN програє k-середнім на UGRansome (ARI 0.0837 проти 0.2010): у даних немає вираженої щільнісної структури, і алгоритм переходить від 226 дрібних кластерів із 27 % шуму одразу до двох злиплих, без придатного проміжного режиму.
2. Слабкість алгоритму на цих даних — властивість даних, а не методу. На концентричних колах DBSCAN дає ARI 1.0000, тоді як k-середніх — −0.0006, тобто гірше за випадкове розбиття, бо шукає лише кулясті скупчення.
3. Точки-шум лише слабко відповідають аномаліям: lift 1.42×, тобто 59 % позначених точок аномаліями не є. Як самостійний детектор непридатні; щільнісна ізольованість не збігається з міткою аналітика.
4. Різниця між моделями A і B статистично значуща ($p < 10^{-15}$ за обома критеріями), причому перевага майже одностороння: у 347 випадках B виправляє помилку A і лише у 19 навпаки.
5. Критерій Мак-Немара коректніший за z-тест для порівняння моделей на спільній тестовій вибірці, бо враховує парність спостережень і спирається лише на 366 розбіжних пар замість усіх 4 500.
6. Підглядання руйнує рівень значущості: 20 проміжних перевірок підвищують частку хибнопозитивних висновків з 5.3 % до 24.5 %. Обсяг вибірки слід фіксувати до початку експерименту.

7 Джерела

1. UGRansome dataset. URL: https://www.kaggle.com/datasets/nkongolo/ugransome-dataset
2. Ester M., Kriegel H.-P., Sander J., Xu X. A Density-Based Algorithm for Discovering Clusters // KDD. 1996. P. 226–231.
3. McNemar Q. Note on the sampling error of the difference between correlated proportions or percentages // Psychometrika. 1947. Vol. 12. P. 153–157.
4. Kohavi R., Tang D., Xu Y. Trustworthy Online Controlled Experiments. Cambridge University Press, 2020.