МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ імені ІГОРЯ СІКОРСЬКОГО»

Навчально-науковий фізико-технічний інститут

Кафедра інформаційної безпеки

ЗВІТ

з дисципліни «Аналіз кіберінцидентів»

Практичне заняття № 9 — Нейронні мережі

Виконав: Вовкотруб Олександр Віталійович
Група: ФБ-61мн

Перевірив: Наконечна Юлія Володимирівна

Київ — 2026

Зміст

1 Мета роботи **2**

2 Постановка задачі **2**

2.1 Теорія 2

3 Хід виконання **2**

3.1 Розмір прихованого шару 2

3.2 Перевірка правил методички 3

3.3 Глибина та форма мережі 4

3.4 Функція активації 4

3.5 Регуляризація 5

3.6 Що вивчила мережа 6

3.7 Ефективність підсумкової мережі 6

4 Результати **7**

5 Аналіз **8**

6 Висновки **8**

7 Джерела **9**

1 Мета роботи

Створити нейронну мережу для розпізнавання рукописних цифр, навчити її на наборі MNIST, оцінити ефективність на нових зображеннях і перевірити правила вибору архітектури, наведені в методичних вказівках.

2 Постановка задачі

Використано датасет MNIST: 10 000 зображень 28×28 у відтінках сірого, 784 ознаки-пікселі, 10 збалансованих класів. Той самий набір і той самий поділ, що в практичному занятті № 7, тож результат порівнюється з шістьма іншими алгоритмами курсу безпосередньо.

Пікселі нормовано до діапазону $[0, 1]$: за вихідних значень 0–255 градієнти на початку навчання завеликі й збіжність погіршується.

Числа з практичного заняття № 7 виміряно на непронормованих пікселях, тому для чутливих до масштабу методів вони відрізняються, найпомітніше для логістичної регресії (0.8816 проти 0.9048).

2.1 Теорія

Штучний нейрон підсумовує зважені входи й пропускає результат через функцію активації: $y = f(\sum_i w_i x_i + b)$. Мережа без прихованих шарів, з однією сигмоїдною активацією на виході, це в точності логістична регресія з практичного заняття № 1; додавання прихованого шару і є узагальненням. Навчання виконується зворотним поширенням помилки.

Методичні вказівки наводять два кількісні орієнтири, які буде перевірено емпірично, а не просто процитовано:

1. Теорема Колмогорова: «немає сенсу обирати кількість прихованих нейронів більшу за подвоєну кількість вхідних», тобто $2 \cdot 784 + 1 = 1569$.
2. Достатність даних: $w < n/e$, де w це кількість ваг, n це кількість навчальних прикладів, e це прийнятна похибка.

3 Хід виконання

3.1 Розмір прихованого шару

Нейронів	Ваг	Ваг на приклад	Навчальна	Тестова	Розрив
10	7 960	1.06	0.9812	0.9136	0.0676
25	19 885	2.65	0.9999	0.9324	0.0675
50	39 760	5.30	1.0000	0.9440	0.0560
100	79 510	10.60	1.0000	0.9456	0.0544

Нейронів	Ваг	Ваг на приклад	Навчальна	Тестова	Розрив
200	159 010	21.20	1.0000	0.9536	0.0464
400	318 010	42.40	1.0000	0.9556	0.0444
800	636 010	84.80	1.0000	0.9596	0.0404

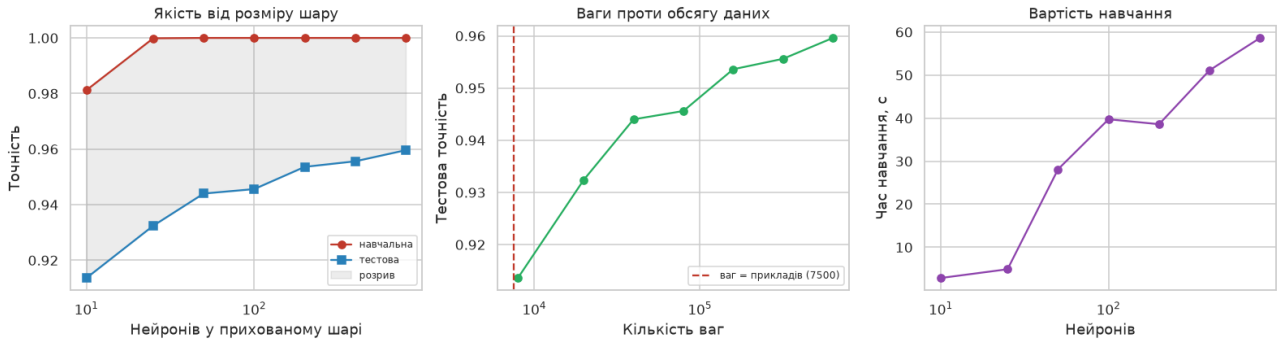


Рисунок 1: Розмір прихованого шару

Результат суперечить класичному очікуванню. Починаючи з 25 нейронів мережа досягає 100 % на навчальній вибірці, тобто повністю запам'ятовує дані. За класичною логікою подальше збільшення кількості параметрів має посилювати перенавчання. Насправді ж тестова точність монотонно зростає (0.9136 → 0.9596), а розрив між навчальною й тестовою вибірками монотонно спадає (0.0676 → 0.0404), попри те, що в найбільшій мережі припадає 85 ваг на один навчальний приклад.

3.2 Перевірка правил методички

Правило 1, межа Колмогорова (1 569 нейронів). Найбільша випробувана мережа має 800 нейронів, тобто лише 51 % межі, і точність на ній ще зростає. Правило не є хибним, але й не є практичним орієнтиром: воно задає стелю, до якої зростання якості не встигає зупинитись.

Правило 2, $w < n/e$, що рівносильне $e < n/w$:

Нейронів	Ваг	Прогноз $e <$	Фактична e	Правило
10	7 960	0.942	0.086	виконано
100	79 510	0.094	0.054	виконано
200	159 010	0.047	0.046	виконано (на межі)
400	318 010	0.024	0.044	порушено
800	636 010	0.012	0.040	порушено

Правило виконується до 200 нейронів і порушується далі, але в консервативний бік. Воно стверджує, що за 636 010 ваг і 7 500 прикладів похибка не може бути меншою за 1.2 %; фактично мережа дає 4.0 %, тобто гірше за прогноз. Тобто правило не «зламалося»

в небезпечний бік, воно просто надто песимістичне і як орієнтир для вибору архітектури непридатне.

Обидва правила походять з класичної теорії ємності моделей, яка погано описує поведінку нейронних мереж у режимі надпараметризації. Емпіричне спостереження з таблиці вище, зростання якості при зростанні кількості параметрів далеко за межу обсягу даних, є сучасним і добре відтвореним явищем.

3.3 Глибина та форма мережі

Архітектура	Ваг	Навчальна	Тестова
1 шар (100)	79 510	1.0000	0.9456
2 шари (100, 100)	89 610	1.0000	0.9608
3 шари (100, 100, 100)	99 710	1.0000	0.9512
Звужувана (300, 100, 30)	268 940	1.0000	0.9576
Розширювана (30, 100, 300)	59 960	1.0000	0.9548

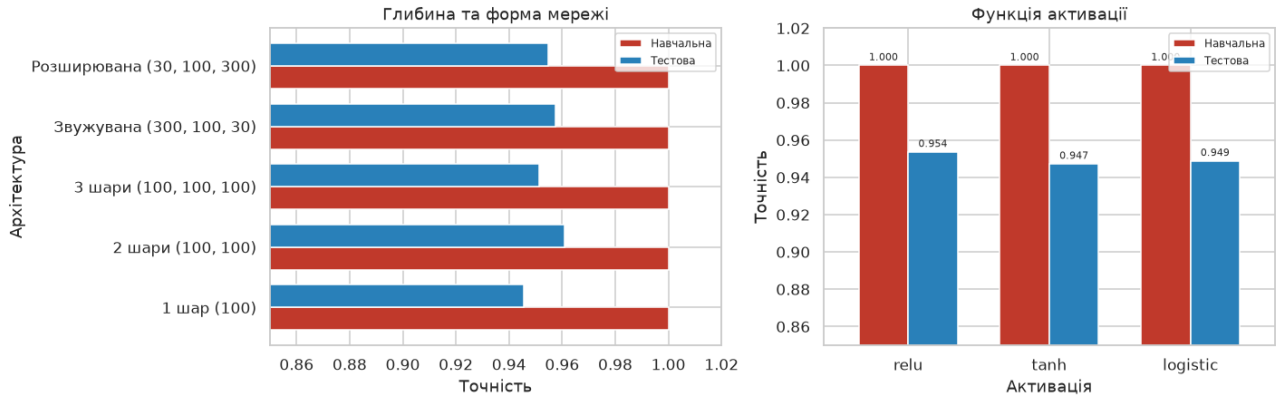


Рисунок 2: Глибина та активація

Другий шар додає 1.5 пункта (0.9456 → 0.9608) за майже незмінної кількості ваг: дешеве покращення. Але третій шар погіршує результат до 0.9512: глибина не дає монотонного виграшу, і для повнозв’язних мереж на такій задачі оптимум досягається рано.

Методичка згадує вибір між звужуваною та розширюваною мережею. Обидві дали близькі результати (0.9576 і 0.9548), причому звужувана потребує вчетверо більше ваг. На цій задачі форма мережі виявилась менш важливою за кількість шарів.

3.4 Функція активації

Активація	Тестова	Ітерацій
relu	0.9536	70
tanh	0.9472	80
logistic	0.9488	100 (ліміт)

Різниця в точності незначна (0.6 пункта), але швидкість збіжності відрізняється суттєво. `relu` збігся за 70 ітерацій, `tanh` за 80, а сигмоїда вперлася в ліміт `max_iter` = 100, тобто навчання було обірване, а не завершене: її похідна затухає на краях діапазону, градієнт слабшає, і оновлення ваг стають мізерними.

3.5 Регуляризація

alpha	Навчальна	Тестова	Розрив
10^{-6}	1.0000	0.9556	0.0444
0.01	1.0000	0.9568	0.0432
0.1	1.0000	0.9580	0.0420
1.0	0.9787	0.9448	0.0339
10.0	0.8936	0.8804	0.0132

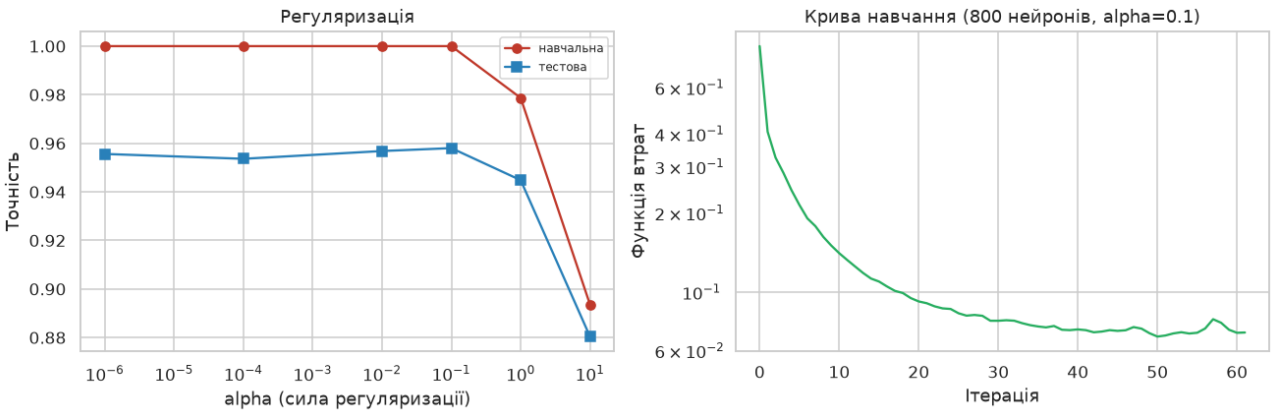


Рисунок 3: Регуляризація та крива навчання

Оптимум за $\alpha = 0.1$, але виграш скромний, 0.2 пункта. Показовим є рядок $\alpha = 10$: розрив між вибірками падає до 0.0132, тобто перенавчання майже зникає, проте разом з ним зникає й якість (0.8804). Мінімальний розрив не є метою; він досягається і тоді, коли модель просто нічого не вивчила.

3.6 Що вивчила мережа

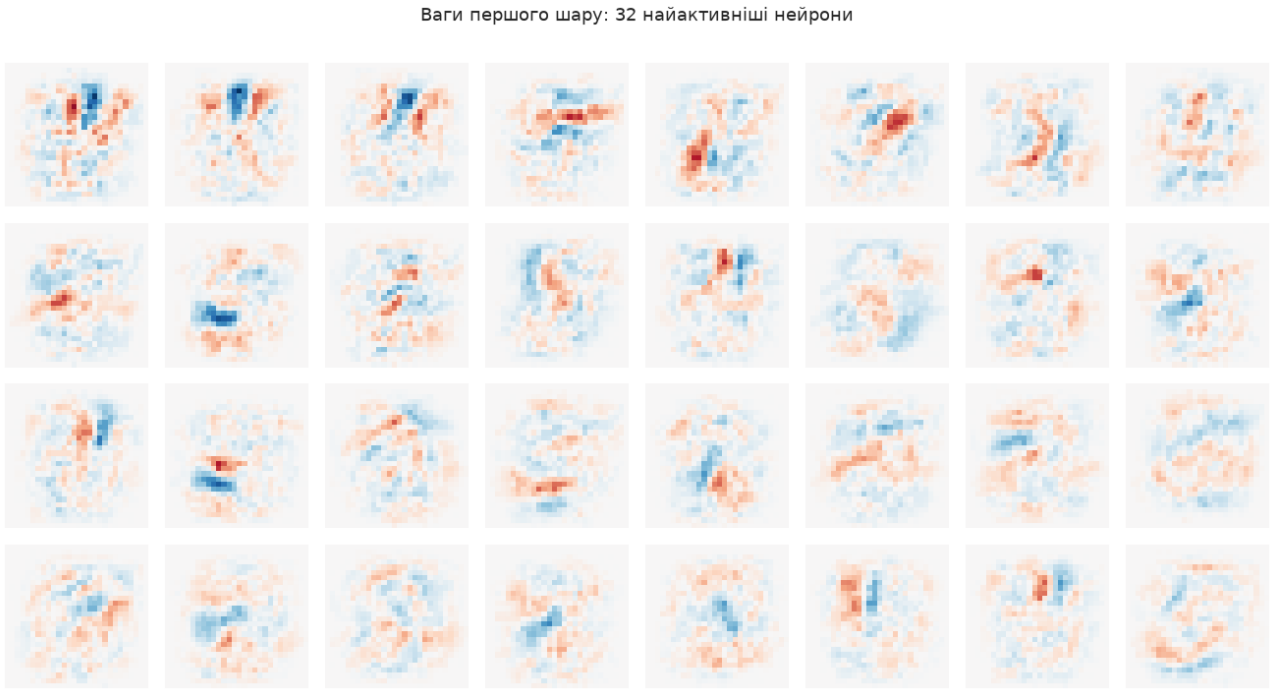


Рисунок 4: Ваги першого шару

Ваги першого шару утворюють просторові шаблони: області, чутливі до наявності або відсутності штриха в певній частині зображення. Мережа самостійно виділила локальні ознаки, хоча її архітектура не має жодного вбудованого уявлення про двовимірну структуру: на вхід подавався просто вектор із 784 чисел.

3.7 Ефективність підсумкової мережі

Підсумкова конфігурація: 800 нейронів, $\alpha = 0.1$, активація relu. Точність на нових зображеннях 0.9652, F1-macro 0.9649.

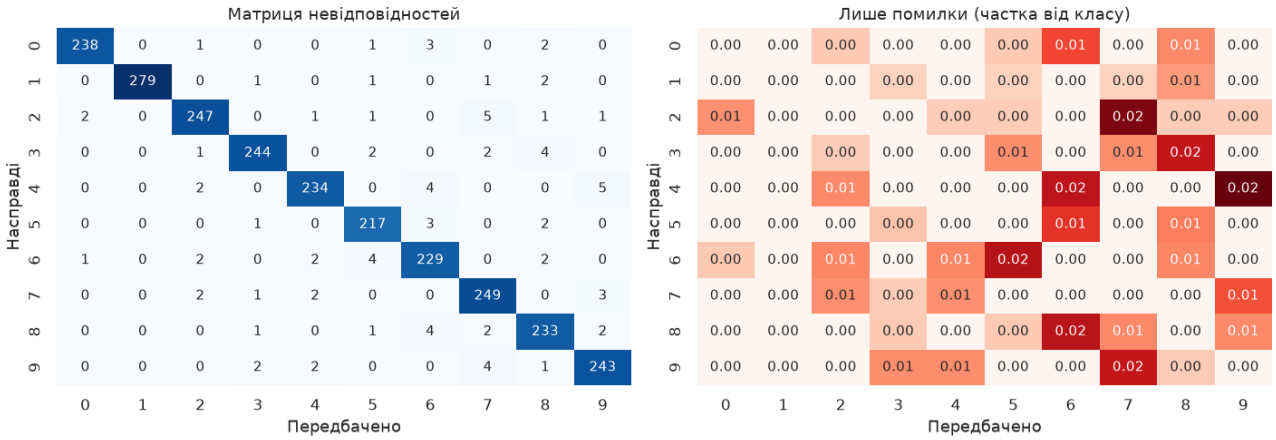


Рисунок 5: Матриці невідповідностей



Рисунок 6: Приклади помилок

Плутанина	Разів
2 → 7	5
4 → 9	5
3 → 8	4
4 → 6	4

Помилки припадають на візуально схожі пари: 4 і 9 різняться лише замкненістю верхньої петлі, 3 і 8 наявністю лівої частини, 2 і 7 наявністю нижньої горизонталі. Найгірше розпізнається цифра 6 (F1 = 0.9482), найкраще цифра 1 (F1 = 0.9911), що логічно: одиниця має найпростішу й найстабільнішу форму.

4 Результати

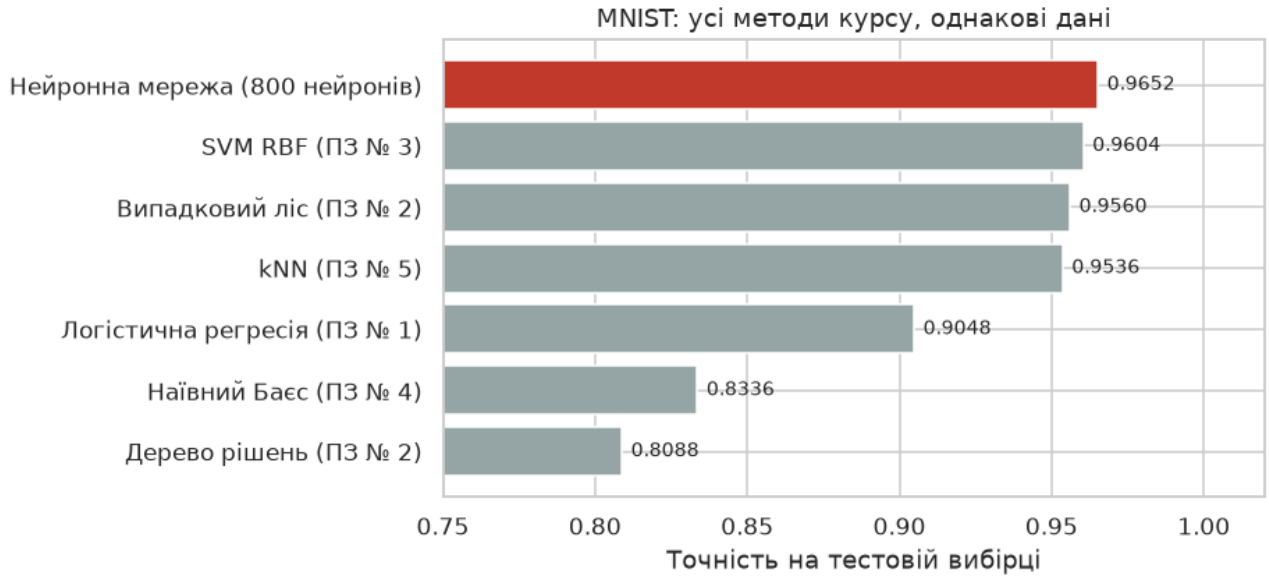


Рисунок 7: Порівняння всіх методів курсу

Модель	Точність
Нейронна мережа (800 нейронів)	0.9652
SVM RBF (ПЗ № 3)	0.9604
Випадковий ліс (ПЗ № 2)	0.9560
kNN (ПЗ № 5)	0.9536
Логістична регресія (ПЗ № 1)	0.9048
Наївний Баєс (ПЗ № 4)	0.8336
Дерево рішень (ПЗ № 2)	0.8088

5 Аналіз

Нейронна мережа перемогла всі методи курсу на цих даних, випередивши SVM на 0.5 пункта, а дерево рішень на 15.6. Проте варто пам'ятати результати попередніх робіт: на табличних даних UGRansome дерево давало 0.9943 і впевнено перевершувало SVM та kNN. Жоден метод не є універсально найкращим: упорядкування визначається природою даних, і за дев'ять практичних робіт воно змінювалось щонайменше тричі.

Причина переваги мережі на зображеннях у тому, що вона будує власні ознаки. Дерево розбиває простір по одному пікселю за раз, а окремий піксель тут майже нічого не означає. Мережа ж у прихованому шарі формує комбінації пікселів, фактично детектори штрихів, і класифікує вже за ними.

Ціна цієї переваги обчислювальна. Навчання найбільшої мережі тривало 62.6 с проти 0.60 с у випадкового лісу, тобто у 104 рази довше, заради 0.9 пункта точності. Для практичної системи виявлення інцидентів такий обмін не завжди виправданий.

Про перевірку правил. Обидва орієнтири з методички виявились непридатними для вибору архітектури: межа Колмогорова надто висока, щоб бути обмеженням, а правило $w < n/e$ надто песимістичне. Найкраща мережа має у 85 разів більше ваг, ніж навчальних прикладів, і саме вона узагальнює найкраще. Це не помилка в методичці, це відображення того, що класична теорія ємності моделей була розроблена до появи сучасних результатів про надпараметризовані мережі.

6 Висновки

1. Нейронну мережу для розпізнавання рукописних цифр створено й навчено; підсумкова конфігурація (800 нейронів, $\alpha = 0.1$, relu) дала точність 0.9652 на нових зображеннях за F1-macro 0.9649.
2. Мережа перевершила всі шість інших методів курсу на MNIST (SVM 0.9604, ліс 0.9560, дерево 0.8088), бо самостійно будує ознаки з комбінацій пікселів, тоді як окремий піксель майже неінформативний.

3. Правила з методичних вказівок перевірено й не підтверджено як практичні орієнтири: межа Колмогорова (1 569 нейронів) не досягнута навіть наполовину, а правило $w < n/e$ порушується від 400 нейронів, причому в консервативний бік.
4. Надпараметризація не зашкодила: за 85 ваг на один навчальний приклад розрив між навчальною й тестовою вибірками не зріс, а скоротився з 0.0676 до 0.0404, і тестова точність монотонно зростала.
5. Глибина не дає монотонного виграшу: другий шар додає 1.5 пункта, третій віднімає 1.0. Функція активації впливає слабко на точність (0.6 пункта), але помітно на швидкість збіжності: relu збігся за 70 ітерацій, а сигмоїда за відведені 100 не збіглася взагалі.
6. Мінімальний розрив між вибірками не є метою: за $\alpha = 10$ розрив падає до 0.0132, але точність падає до 0.8804, бо модель перестає вчитися.
7. Помилки припадають на візуально схожі пари цифр ($4 \leftrightarrow 9$, $3 \leftrightarrow 8$, $2 \leftrightarrow 7$), що свідчить про вичерпання інформації, доступної повнозв'язній мережі без урахування двовимірної структури зображення.

7 Джерела

1. MNIST Dataset. URL: https://www.kaggle.com/datasets/wasiqaliyasir/digital-mnist-dataset
2. LeCun Y., Bottou L., Bengio Y., Haffner P. Gradient-based learning applied to document recognition // Proceedings of the IEEE. 1998. Vol. 86, № 11. P. 2278–2324.
3. Rumelhart D., Hinton G., Williams R. Learning representations by back-propagating errors // Nature. 1986. Vol. 323. P. 533–536.
4. Belkin M., Hsu D., Ma S., Mandal S. Reconciling modern machine-learning practice and the classical bias–variance trade-off // PNAS. 2019. Vol. 116, № 32. P. 15849–15854.
5. Scikit-learn: Neural network models. URL: https://scikit-learn.org/stable/modules/neural_networks_supervised.html